

Analyse de valeurs extrêmes

Travail Encadré de Recherche

Carmel AWANDE & Yves GNONHOUE

Université d'Angers

21 mai 2026

- 1 Introduction
- 2 Cadre Théorique
- 3 Estimation des Paramètres
- 4 Application sur données réelles
- 5 Conclusion

- La théorie des valeurs extrêmes (TVE) étudie les événements rares ayant une faible probabilité d'occurrence mais pouvant avoir des impacts majeurs.
- Contrairement aux méthodes statistiques classiques centrées sur la moyenne, la TVE se focalise sur l'analyse et la modélisation des valeurs extrêmes.
- Les valeurs extrêmes apparaissent dans plusieurs domaines : hydrologie, météorologie, finance, assurance et sciences sociales.
- Ce projet vise à présenter les bases de la TVE, les modèles classiques d'estimation des paramètres extrêmes et une application en hydrologie.

La question principale est comment modéliser et estimer les événements rares à partir des observations disponibles, sachant que ces événements se produisent peu fréquemment et apparaissent très rarement dans les jeux de données ?

Notion de domaine d'attraction

Soit $X_1, \dots, X_n$ une suite de variables aléatoires i.i.d. de fonction de répartition F , et soit

$$X_{n:n} = \max(X_1, \dots, X_n).$$

On dit que F appartient au **domaine d'attraction** d'une fonction de répartition G s'il existe des suites de constantes $(a_n)_{n \geq 1}$ avec $a_n > 0$ et $(b_n)_{n \geq 1}$ telles que

$$P\left(\frac{X_{n:n} - b_n}{a_n} \leq x\right) \longrightarrow G(x), \quad \text{lorsque } n \rightarrow \infty.$$

Distributions à queue lourde

Une distribution est dite leptokurtique (à queue lourde) si $\text{Kurtosis} > 3$.

$$\text{Kurtosis} = \frac{\mathbb{E}[(X - \mu)^4]}{(\mathbb{E}[(X - \mu)^2])^2} \quad (1)$$




Figure – Comparaison entre une queue dégénérée (Normale) et une queue lourde

Notion de probabilité de dépassement et de période de retour

Probabilité de dépassement

Le risque associé à un événement extrême est mesuré par la probabilité qu'une variable aléatoire X dépasse un seuil critique élevé u :

$$P(X > u) = \bar{F}(u) \quad (2)$$

$\bar{F}$ représente la fonction de survie

Période de retour

La période de retour T représente le temps moyen séparant deux événements extrêmes. Si un événement possède une probabilité annuelle de dépassement p , alors :

$$T = \frac{1}{p} = \frac{1}{1 - F(u)} \quad (3)$$

Comportement asymptotique de la distribution du maximum

$$P(X_{n:n} \leq x) = [F(x)]^n. \quad (4)$$

$$F_{X_{n:n}}(x) = \lim_{n \rightarrow \infty} (F(x))^n = \begin{cases} 0 & \text{si } F(x) < 1 \\ 1 & \text{si } F(x) = 1 \end{cases} \quad (5)$$

Theorem (Fisher-Tippett-Gnedenko)

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires i.i.d. avec fonction de répartition F . S'il existe deux suites normalisantes $(a_n)_{n \geq 1}$, $a_n > 0$, et $(b_n)_{n \geq 1}$ ($b_n \in \mathbb{R}$) telles que la loi du maximum normalisé converge vers une loi H_ξ , alors :

$$\lim_{n \rightarrow \infty} P\left(\frac{X_{n:n} - b_n}{a_n} \leq x\right) = \lim_{n \rightarrow \infty} F^n(a_n x + b_n) = H_\xi(x), \quad x \in \mathbb{R} \quad (6)$$

Loi des maxima (GEV)

H_ξ prend l'une des formes suivantes :

- **Loi de Gumbel** : Support $\mathbb{R}$

$$\Lambda(x) = \exp(-\exp(-x)), \quad x \in \mathbb{R} \quad (7)$$

- **Loi de Fréchet** Support $\left] \mu - \frac{\sigma}{\xi}, +\infty \right[$

$$\phi_\alpha(x) = \begin{cases} 0, & x \leq 0, \\ \exp(-x^{-\alpha}), & x > 0, \alpha > 0 \end{cases} \quad (8)$$

- **Loi de Weibull** : Support $\left] -\infty, \mu - \frac{\sigma}{\xi} \right[$

$$\psi_\alpha(x) = \begin{cases} \exp(-(-x)^\alpha), & x \leq 0, \\ 1, & x > 0, \alpha > 0 \end{cases} \quad (9)$$


Ces trois distributions sont appelées loi des valeurs extrêmes

Loi Généralisée des Valeurs Extrêmes (GEV)

Introduite par von Mises (1954) et formalisée par Jenkinson (1955), la fonction de répartition de la loi GEV est donnée par :

$$F(x) = \begin{cases} \exp \left(- \left[1 + \xi \frac{x-\mu}{\sigma} \right]_+^{-1/\xi} \right), & \xi \neq 0, \\ \exp \left(- \exp \left(-\frac{x-\mu}{\sigma} \right) \right), & \xi = 0 \end{cases} \quad (10)$$

où $x_+ = \max(x, 0)$.



Principe

- **Approche Peaks-Over-Threshold (POT)** : Analyse des valeurs dépassant un seuil u .
- **Théorème de Pickands** : La distribution des excès converge vers la loi de Pareto Généralisée (GPD).
- **Avantage** : Utilise plus de données que la méthode des maxima.

Distribution de Pareto généralisée (GPD)


Pour tout $x > 0$, la densité s'écrit :

$$g_{\xi,\sigma}(x) = \begin{cases} \frac{1}{\sigma} \left(1 + \xi\left(\frac{x}{\sigma}\right)\right)^{-\frac{1}{\xi}-1}, & \text{si } 1 + \xi\left(\frac{x}{\sigma}\right) > 0, \xi \neq 0, \\ \frac{1}{\sigma} \exp\left(-\frac{x}{\sigma}\right), & \text{si } x > 0, \xi = 0. \end{cases} \quad (11)$$

Support de la GPD

avec le support défini par :

$$\begin{cases} x \geq 0 & \text{si } \xi \geq 0, \\ 0 \leq x \leq -\frac{\sigma}{\xi} & \text{si } \xi < 0. \end{cases}$$



- **Paramétriques** : Maximum de vraisemblance et méthode des moments.
- **Semi-paramétriques** : Estimateur de Hill.

Estimateur de Hill

$$\hat{\gamma}_H = \frac{1}{k} \sum_{i=0}^{k-1} \ln(X_{n-i:n}) - \ln(X_{n-k:n})$$

Dépend du choix de k (nombre d'extrêmes retenus).

- **Mean Excess Plot** : Utilisé pour identifier le seuil u à partir duquel la distribution devient linéaire.
- **Hill Plot** : Permet de repérer un "plateau de stabilité" pour choisir la valeur optimale de k .
- **Compromis Biais-Variance** : Un seuil trop bas biaise l'estimation ; un seuil trop haut augmente la variance.

Présentation des données

Les données proviennent de la station hydrométrique **L800001020** située sur la Loire à Saumur (Maine-et-Loire, France), appartenant au bassin hydrographique **Loire-Bretagne**. Elles ont été extraites du site *hydro.eaufrance.fr*.

Résumé statistique

Statistiques	Min	1st Qu.	Median	Mean	3rd Qu.	Max	Kurtosis
Valeurs	79500	213146	404624	597286	802754	4750000	8.930401

Table – Résumé statistique des données




Figure : Boîtes à moustaches des débits journaliers




Figure : Débit journalier


Estimation des paramètres GEV

Résultats GEV

Paramètres	IC 95% inf.	Estimation	IC 95% sup.
Localisation ($\hat{\mu}$)	2.177×10^6	2.430×10^6	2.682×10^6
Échelle ($\hat{\sigma}$)	4.901×10^5	7.043×10^5	9.186×10^5
Forme ($\hat{\xi}$)	-4.400×10^{-1}	-1.363×10^{-1}	1.675×10^{-1}

Tableau : Estimation des paramètres de la GEV par MLE

Graphiques de diagnostic



Estimation des paramètres GPD




Figure : Graphique du Mean Excess Plot





Figure : Stabilité de l'indice de queue

Résultats de la GPD

Paramètres	95% lower CI	Estimations	95% upper CI
Échelle ($\hat{\sigma}$)	3.303540×10^5	3.386292×10^5	3.469044×10^5
Forme ($\hat{\xi}$)	-1.188047×10^{-1}	2.686416×10^{-2}	1.725331×10^{-1}

Table – Estimation des paramètres GPD avec intervalles de confiance à 95%

Graphiques de diagnostic



Estimation par la méthode semi paramétriques de Hill




Figure – Paramètres estimés par la l'estimateur semi paramétrique de Hill

Estimation des quantiles de retour

Estimation des quantiles de retour pour le modèle GEV

Période de retour	IC 95% inférieur	Estimation	IC 95% supérieur
5 ans	3043483	3385227	3726971
10 ans	3361786	3794794	4227801
20 ans	3555315	4150203	4745091
50 ans	3658149	4561399	5464649
100 ans	3649367	4837067	6024767
200 ans	3584248	5086846	6589444

Estimation des quantiles de retour pour le modèle GPD

Période de retour	IC 95% inférieur	Estimation	IC 95% supérieur
5 ans	3633432	3820453	4007473
10 ans	3782360	4074671	4366983
20 ans	3905971	4333669	4761367
50 ans	4030536	4683530	5336524
100 ans	4094645	4953971	5813296
200 ans	4131903	5229494	6327086

Limites

- Sensibilité au choix du seuil dans l'approche POT :
 - seuil trop bas $\rightarrow$ biais élevé ;
 - seuil trop élevé $\rightarrow$ variance élevée.
- Les niveaux de retour peuvent varier selon le seuil choisi.
- Les hypothèses d'indépendance et de stationnarité sont souvent violées dans les séries hydrologiques.
- Présence de dépendance temporelle, tendance et saisonnalité.

Perspectives

- Modèles extrêmes non stationnaires.
- Approches multivariées ou spatiales.
- Amélioration de la robustesse des estimations.

- La théorie des valeurs extrêmes (GEV et GPD) permet de modéliser efficacement les événements rares et d'estimer les niveaux de risque associés.
- L'application aux données hydrologiques de la Loire à Saumur a mis en évidence la présence d'extrêmes importants et confirmé l'intérêt de ces modèles pour l'étude des risques d'inondation.
- Malgré leur efficacité, ces modèles présentent des limites liées au choix du seuil, à la taille des échantillons extrêmes et à l'incertitude des extrapolations, ouvrant la voie à des modèles plus avancés (non stationnaires).

Merci pour votre attention