Analyse des Déterminants du Prix Immobilier: approche par PCR et PLS

Carmel AWANDE & Yves GNONHOUE (M1 Data Science)

Introduction

Le prix des biens immobiliers dépend d'un ensemble complexe de caractéristiques structurelles, environnementales et fonctionnelles. Comprendre l'influence de ces facteurs et identifier ceux qui contribuent le plus à la formation du prix constitue un enjeu essentiel pour l'analyse du marché immobilier.

Dans ce projet, nous étudions un jeu de données regroupant diverses variables décrivant la surface, l'aménagement, les équipements et la configuration des logements, afin d'explorer leurs relations et de modéliser le prix de vente.

Objectif

- L'objectif principal de ce projet est d'identifier et de modéliser les facteurs qui influencent le prix de vente des biens immobiliers.

Description des variables

LotFrontage :longueur (en pieds) de façade donnant sur la rue	LotArea :superficie du terrain en pieds carrés	MasVnrArea :surface du parement en maçonnerie (en pieds carrés)	BsmtFinSF1:superficie aménagée de type 1 (en pieds carrés)	BsmtFinSF2: superficie aménagée de type 2 (en pieds carrés)	BsmtUnfSF: superficie non aménagée du sous-sol (en pieds carrés)
TotalBsmtSF: superficie totale du sous-sol (en pieds carrés)	1stFlrSF: superficie du premier étage (en pieds carrés)	2ndFlrSF: superficie du deuxième étage (en pieds carrés)	LowQualFinSF: superficie aménagée de faible qualité (tous étages)	GrLivArea: superficie habitable hors sous-sol (en pieds carrés)	BsmtFullBath: nombre de salles de bain complètes au sous-sol
BsmtHalfBath: nombre de demi-salles de bain au sous-sol	FullBath: nombre de salles de bain complètes hors sous-sol	HalfBath: nombre de demi-salles de bain hors sous-sol	BedroomAbvGr: nombre de chambres au-dessus du sous-sol	KitchenAbvGr : nombre de cuisines	TotRmsAbvGrd: nombre total de pièces hors sous-sol (hors salles de bain)
Fireplaces : nombre de cheminées	GarageCars: capacité du garage (en nombre de voitures)	GarageArea: superficie du garage (en pieds carrés)	WoodDeckSF: superficie de la terrasse en bois (en pieds carrés)	OpenPorchSF: superficie du porche ouvert (en pieds carrés)	EnclosedPorch: superficie du porche fermé (en pieds carrés)
	3SsnPorch: superficie du porche trois saisons (en pieds carrés)	ScreenPorch: superficie du porche avec moustiquaire (en pieds carrés)	PoolArea: superficie de la piscine (en pieds carrés)		

Analyses descriptives

Variable	Min	Q1	Médiane	Moyenne	Q3	Max
LotFrontage	21.00	60.00	70.00	70.67	80.00	313.00
LotArea	1300	7590	9416	10123	11361	215245
MasVnrArea	0.0	0.0	0.0	108.5	170.0	1600.0
BsmtFinSF1	0.0	0.0	374.0	438.4	702.0	5644.0
TotalBsmtSF	0	803	1008	1077	1324	6110
1stFlrSF	438	894	1097	1174	1411	4692
2ndFlrSF	0.0	0.0	0.0	353.3	728.0	2065.0
GrLivArea	438	1155	1479	1531	1776	5642
FullBath	0	1	2	1.581	2	3
BedroomAbvGr	0	2	3	2.864	3	6
GarageCars	1	1	2	1.879	2	4
GarageArea	160	360	484	503	600	1418
SalePrice	35311	131000	164900	185506	219500	755000

Matrice de corrélations

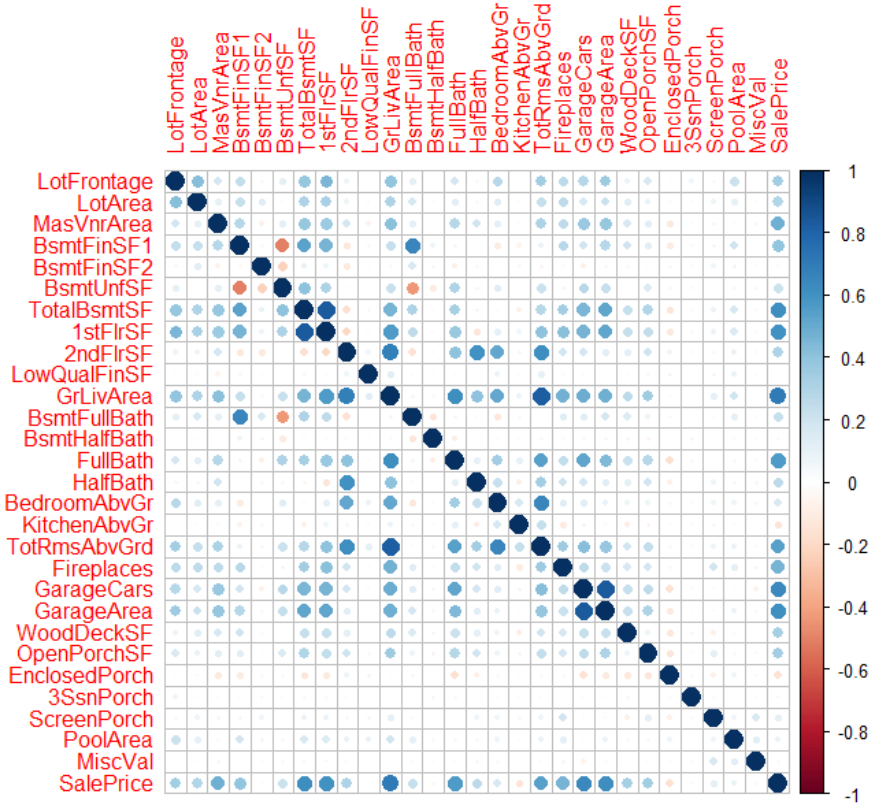

Matrice de corrélations

Présence de fortes corrélations entre plusieurs covariables : Certaines variables liées aux surfaces (TotalBsmtSF, 1stFlrSF, GrLivArea) ainsi que celles liées au garage (GarageArea et GarageCars) sont fortement corrélées, indiquant qu'elles évoluent souvent ensemble.

Risque de multicolinéarité dans le modèle : Ces corrélations élevées montrent que certaines variables apportent une information redondante, ce qui nécessite de faire attention lors de leur inclusion simultanée dans un modèle de régression.

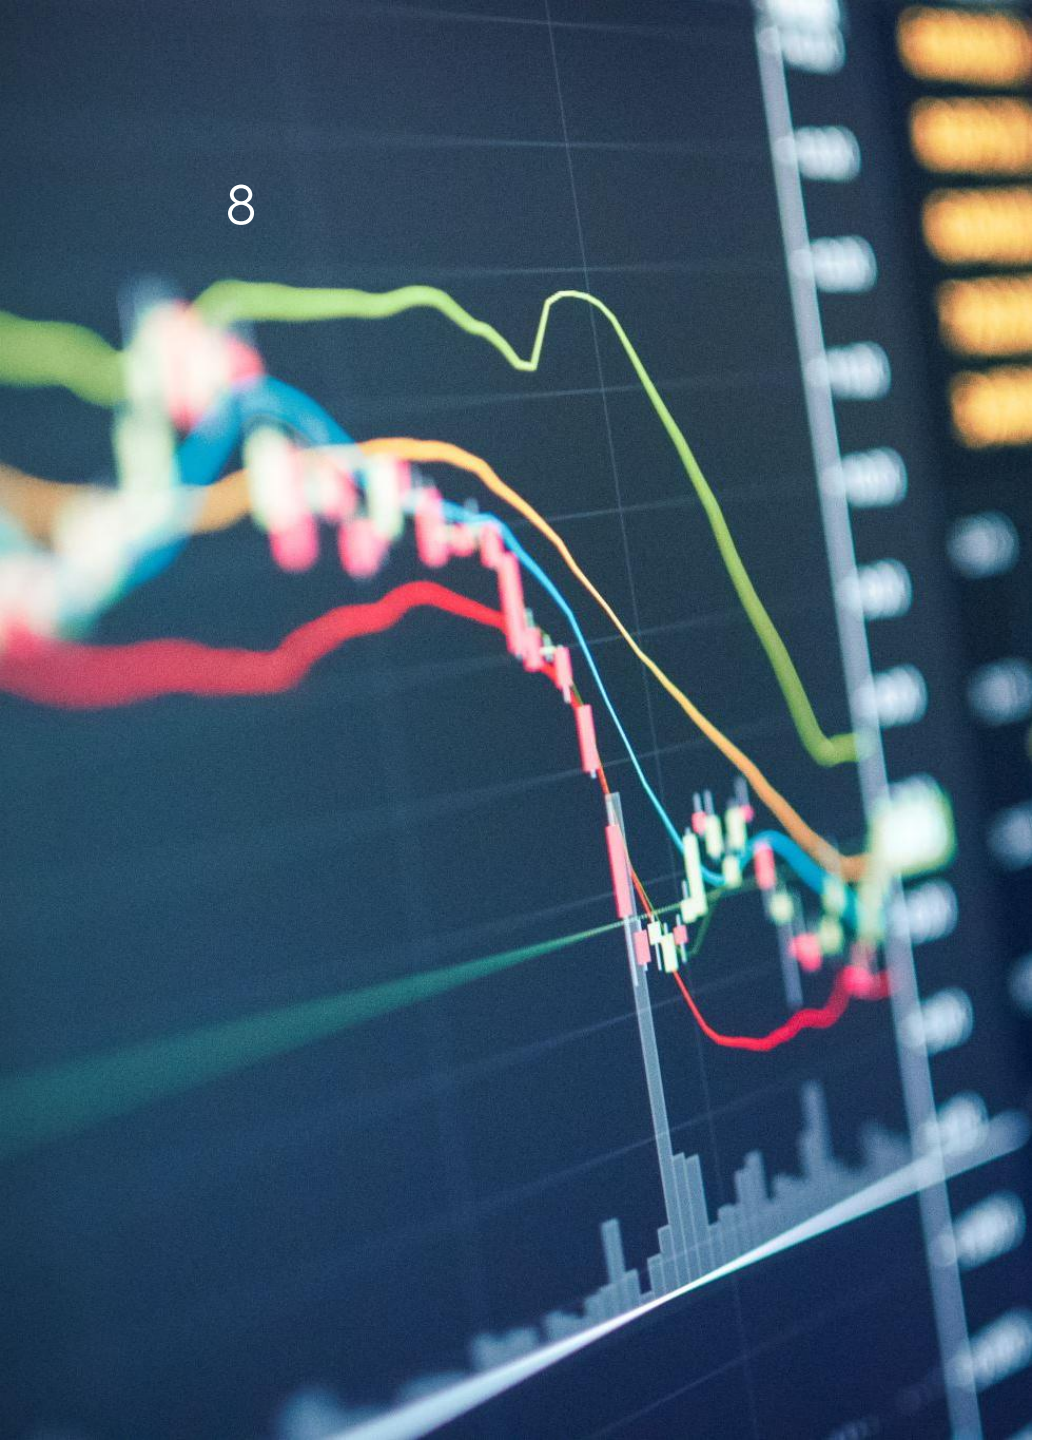

Méthodes d’analyses

La variable dépendante étant le prix de vente du bien en dollars (SalePrice), on s’intéresse à sa prédiction à l’aide de diverses méthodes de régressions qui sont : **la régression linéaire, régression PCR et régression PLS**

Régression linéaire

Pour effectuer la régression linéaire, étant donné que certaines covariables sont fortement corrélées en entre elles, nous les avons retirées avant d'appliquer le modèle afin d'éviter le risque de multicolinéarité. Les résultats issus de l'analyse sont présentés ci-dessous :

Résutats regression linéaire:

- Significativité de plusieurs coffecients
- R carré bon
- Modèle globalement significative (p-value du test de Fisher<5%)

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    3.317e+04  8.951e+03   3.706 0.000221 ***
LotFrontage   -1.269e+01  6.494e+01  -0.195 0.845144
LotArea        3.698e-01  1.762e-01   2.099 0.036072 *
MasVnrArea     3.921e+01  7.761e+00   5.052 5.13e-07 ***
BsmtFinSF1     3.101e+01  6.428e+00   4.824 1.61e-06 ***
BsmtFinSF2     1.793e+01  9.825e+00   1.825 0.068271 .
BsmtUnfSF      2.495e+01  5.731e+00   4.354 1.46e-05 ***
`1stFlrSF`     4.939e+01  8.039e+00   6.143 1.13e-09 ***
`2ndFlrSF`     4.220e+01  6.197e+00   6.811 1.60e-11 ***
LowQualFinSF   8.989e+00  3.076e+01   0.292 0.770124
BsmtFullBath   1.279e+04  3.538e+03   3.614 0.000315 ***
BsmtHalfBath   5.826e+03  5.667e+03   1.028 0.304142
FullBath       2.317e+04  3.351e+03   6.915 7.92e-12 ***
HalfBath       6.571e+03  3.472e+03   1.893 0.058677 .
BedroomAbvGr  -1.602e+04  2.300e+03  -6.966 5.60e-12 ***
KitchenAbvGr  -6.807e+04  6.721e+03 -10.129  < 2e-16 ***
TotRmsAbvGrd   8.002e+03  1.659e+03   4.824 1.60e-06 ***
Fireplaces     7.351e+03  2.409e+03   3.052 0.002329 **
GarageCars     2.607e+04  3.833e+03   6.801 1.70e-11 ***
GarageArea     1.043e+01  1.302e+01   0.801 0.423291
WoodDeckSF     3.501e+01  1.120e+01   3.126 0.001819 **
OpenPorchSF    1.415e+01  2.183e+01   0.648 0.517020
EnclosedPorch -2.491e+01  2.185e+01  -1.140 0.254556
`3SsnPorch`    2.634e+01  4.231e+01   0.623 0.533667
ScreenPorch    5.005e+01  2.283e+01   2.192 0.028602 *
PoolArea      -7.174e+01  3.339e+01  -2.149 0.031875 *
MiscVal       -3.971e+00  7.787e+00  -0.510 0.610195
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 41550 on 1094 degrees of freedom
Multiple R-squared:  0.7552,    Adjusted R-squared:  0.7494
F-statistic: 129.8 on 26 and 1094 DF,  p-value: < 2.2e-16
```

Régression linéaire avec le log(Sales Prices)

Résutats regression linéaire:

- Significativité de plusieurs coffecients également
- R carré > R carré modèle sans log
- Modèle globalement significative (p-value du test de Fisher<5%

```
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.122e+01  4.041e-02 277.694  < 2e-16 ***
LotFrontage    3.288e-04  2.932e-04   1.122 0.262246
LotArea        3.821e-07  7.955e-07   0.480 0.631118
MasVnrArea     5.638e-05  3.504e-05   1.609 0.107880
BsmtFinSF1     1.346e-04  2.902e-05   4.637 3.96e-06 ***
BsmtFinSF2     9.281e-05  4.435e-05   2.092 0.036629 *
BsmtUnfSF      1.325e-04  2.587e-05   5.121 3.58e-07 ***
`1stFlrSF`     1.821e-04  3.629e-05   5.018 6.10e-07 ***
`2ndFlrSF`     1.068e-04  2.797e-05   3.817 0.000143 ***
LowQualFinSF  -4.971e-05  1.388e-04  -0.358 0.720397
BsmtFullBath   9.075e-02  1.597e-02   5.683 1.70e-08 ***
BsmtHalfBath   5.035e-02  2.558e-02   1.968 0.049306 *
FullBath       1.779e-01  1.513e-02  11.760  < 2e-16 ***
HalfBath       8.740e-02  1.567e-02   5.576 3.10e-08 ***
BedroomAbvGr  -4.055e-02  1.038e-02  -3.906 9.97e-05 ***
KitchenAbvGr  -3.455e-01  3.034e-02 -11.390  < 2e-16 ***
TotRmsAbvGrd   2.974e-02  7.488e-03   3.972 7.61e-05 ***
Fireplaces     5.898e-02  1.087e-02   5.424 7.18e-08 ***
GarageCars     1.237e-01  1.730e-02   7.147 1.62e-12 ***
GarageArea     6.654e-05  5.877e-05   1.132 0.257843
WoodDeckSF     1.927e-04  5.056e-05   3.810 0.000147 ***
OpenPorchSF    1.686e-04  9.853e-05   1.712 0.087248 .
EnclosedPorch -1.328e-04  9.863e-05  -1.347 0.178362
`3SsnPorch`    1.966e-04  1.910e-04   1.029 0.303479
ScreenPorch    2.982e-04  1.031e-04   2.893 0.003890 **
PoolArea      -5.888e-04  1.507e-04  -3.907 9.93e-05 ***
MiscVal       -1.223e-05  3.515e-05  -0.348 0.728047
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.1876 on 1094 degrees of freedom
Multiple R-squared:  0.7817,    Adjusted R-squared:  0.7765
F-statistic: 150.7 on 26 and 1094 DF,  p-value: < 2.2e-16
```

Variance Inflator

```
> vif(reg)
  LotFrontage      LotArea   MasVnrArea   BsmtFinSF1   BsmtFinSF2     BsmtUnfSF    `1stFlrSF`
     1.611029     1.331087     1.403139     5.880488     1.559840      4.319747      6.251662
   `2ndFlrSF` LowQualFinSF BsmtFullBath BsmtHalfBath     FullBath      HalfBath BedroomAbvGr
     4.791084     1.061552     2.130512     1.126540     2.203741      1.944879      2.044180
 KitchenAbvGr TotRmsAbvGrd   Fireplaces   GarageCars   GarageArea    WoodDeckSF   OpenPorchSF
     1.254173     4.518701     1.505844     4.080945     4.021342      1.208688      1.281212
EnclosedPorch   `3SsnPorch` ScreenPorch     PoolArea      MiscVal
     1.162855     1.029430     1.129862     1.169730     1.080679
```

Diagnostic du modèle linéaire (Sans log)

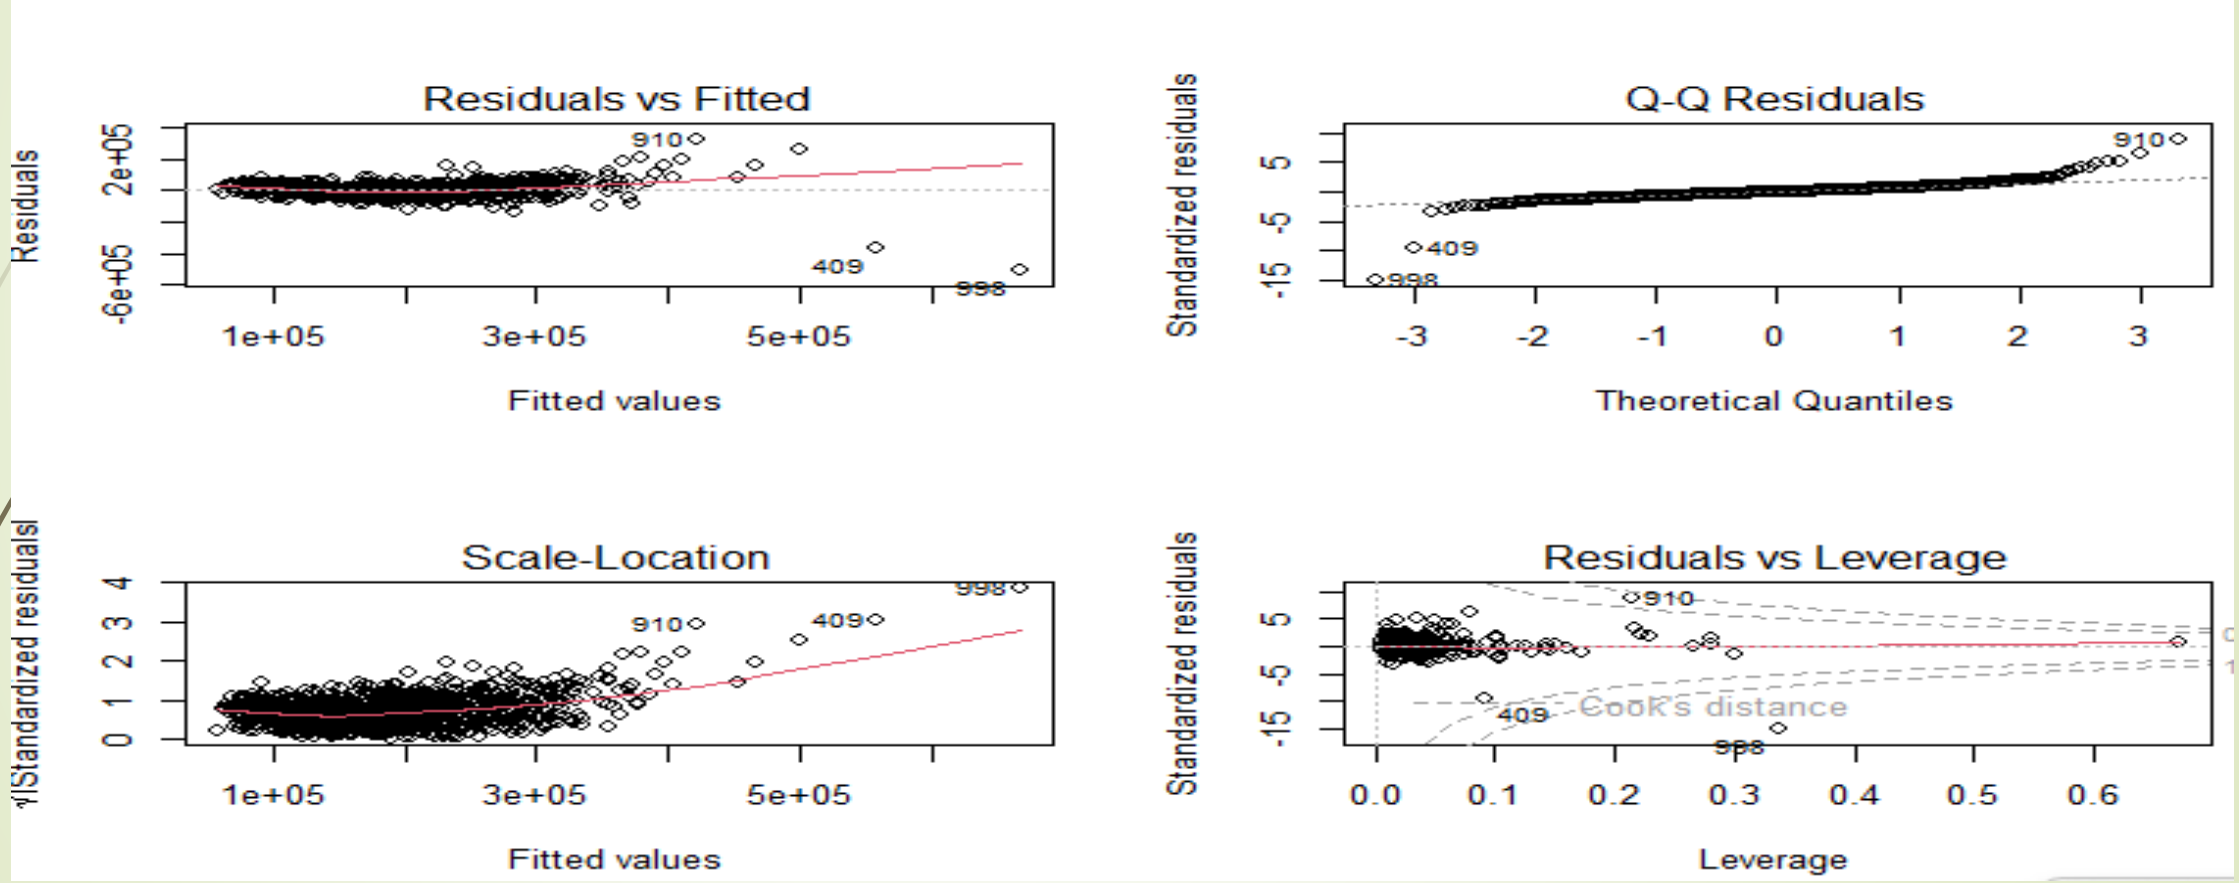

Diagnostic du modèle linéaire (avec log)

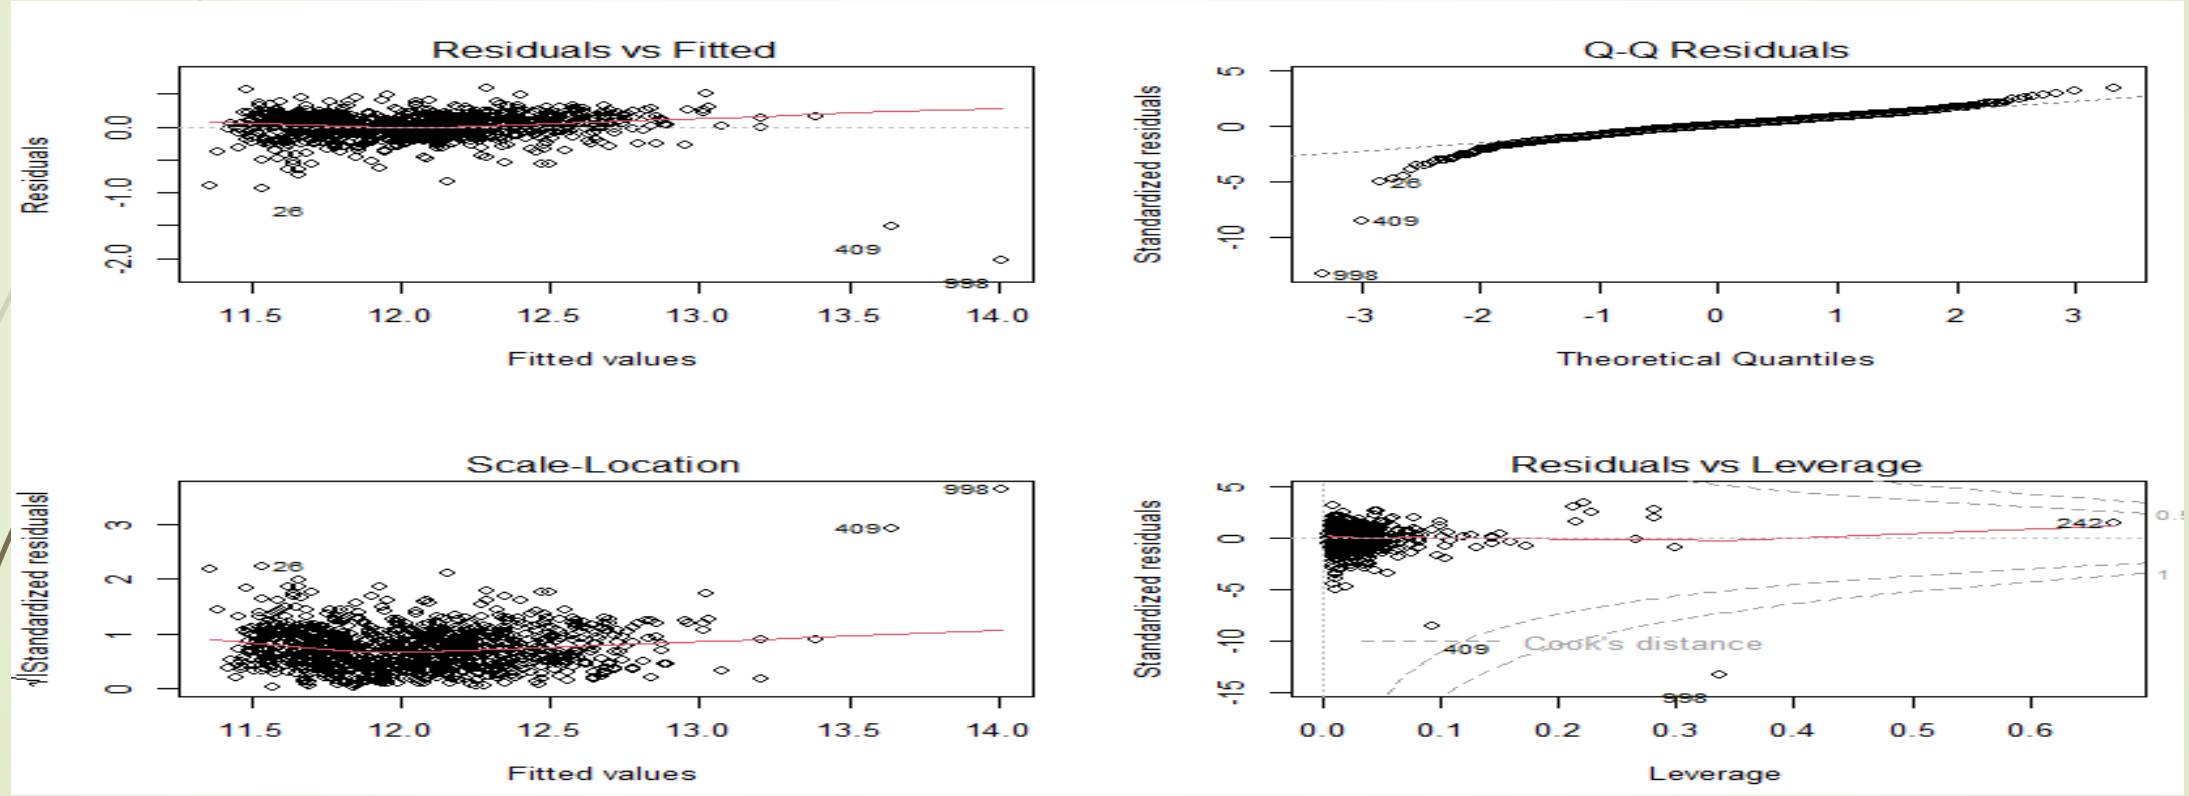

Régression PCR

- Une analyse en composantes principales (ACP) est réalisée sur les covariables afin d'extraire des composantes orthogonales qui maximisent uniquement la variance des covariables, qui sont ensuite utilisées comme variables explicatives dans une régression linéaire.

- **Choix du nombre optimal de composantes** : Le nombre de composantes principales est déterminé par une validation croisée à 10 sous-échantillons, en sélectionnant celui qui minimise le **PRESS (Predicted Residual Sum of Squares)**.

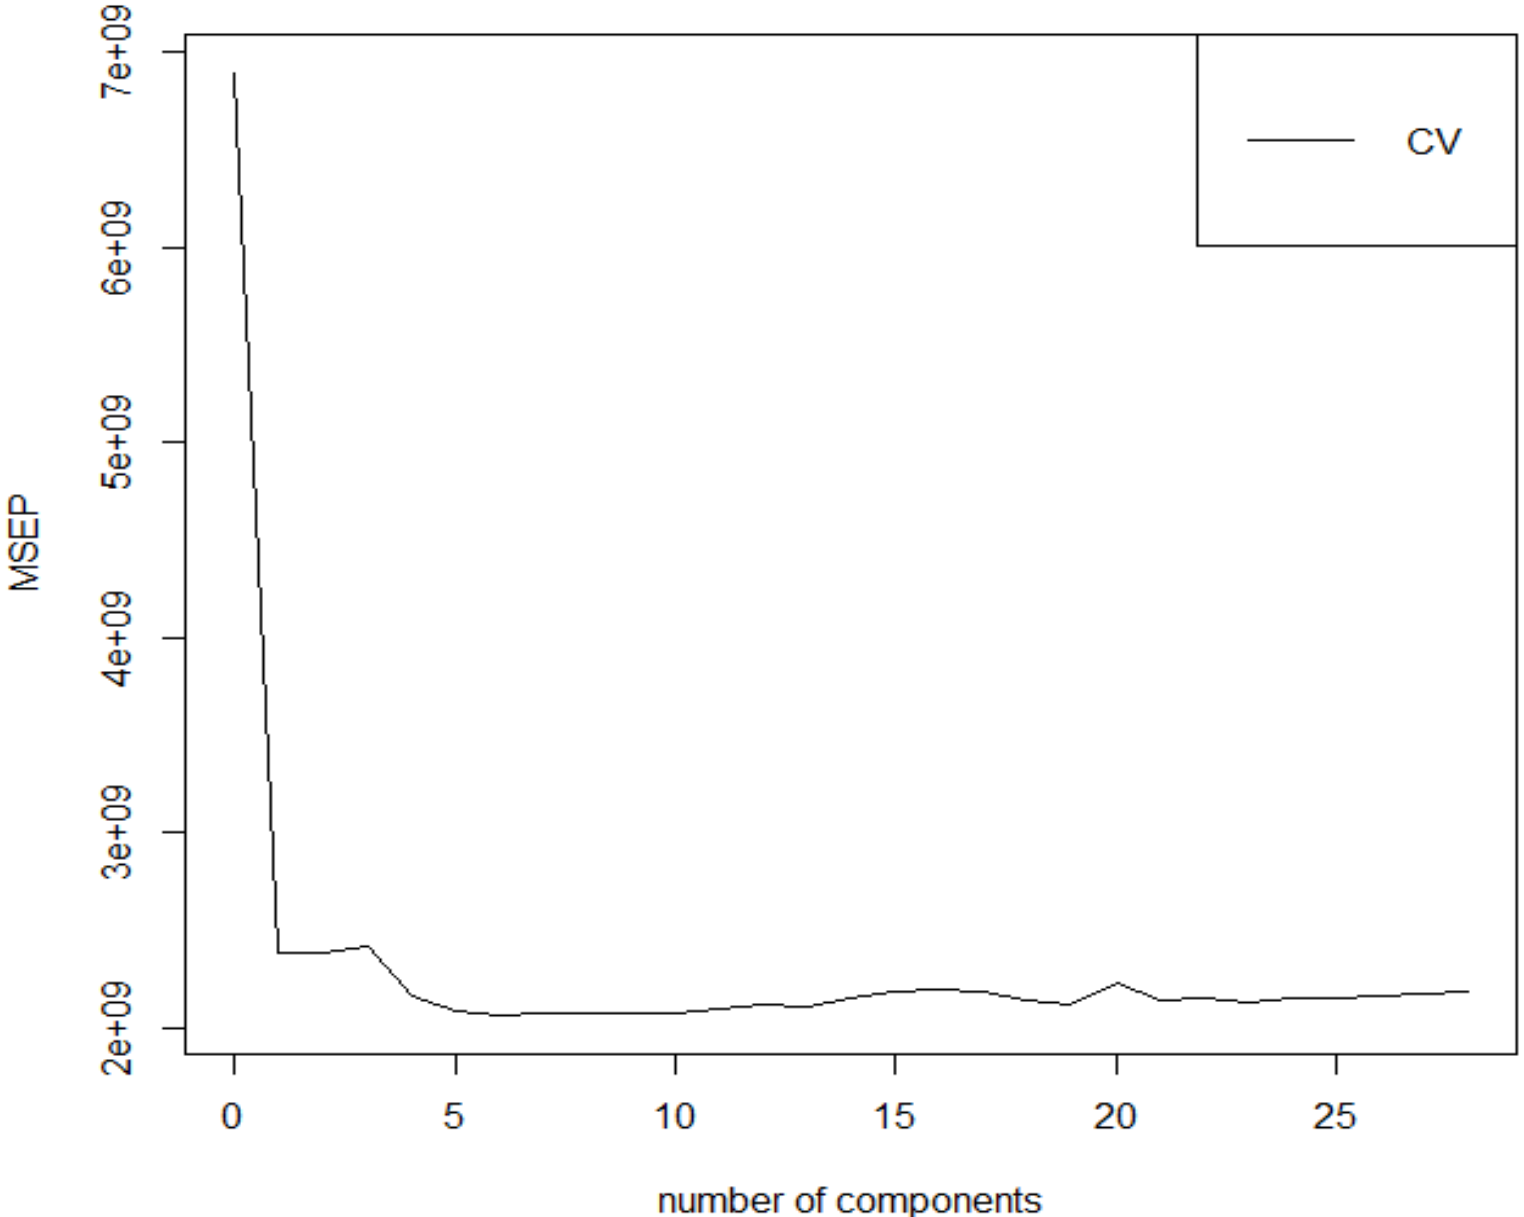

Résultats de la PCR

```
Data:   X dimension: 1121 28
        Y dimension: 1121 1
Fit method: kernelpls
Number of components considered: 6
TRAINING: % variance explained
          1 comps  2 comps  3 comps  4 comps  5 comps  6 comps
X           21.15    27.51    35.44    39.29    42.87    47.25
SalePrice   69.87    74.02    74.80    75.30    75.43    75.48
```

:

- **Variance expliquée des covariables** : La première composante principale explique environ **21,15 %** de la variance des covariables, tandis que les **six premières composantes expliquent environ 47,25 %** de cette variance.
- La première composante explique déjà **69,87 % de la variance de la variable dépendante (SalePrice)**, et l'ajout des cinq autres composantes n'augmente que légèrement cette proportion à **75,48 %**, ce qui montre que l'essentiel de l'information prédictive se trouve dans les premières composantes.

Interprétation des loadings et des weights des covariables

- Les « Loadings » reflètent (mais ne sont pas) les corrélations (qualité de représentation) entre les composantes et les variables explicatives.

Par exemple :

LotFrontage= 0.213*T1 -0.283*T2 -0.234*T3+ 0.104*T4+0.240*T6, avec les T1,T2,….,T6 qui représentes les 6 composantes principales.

- Les weights, représentent la contribution des covariables à la la formation de la composante.

Par exemple:

T1=0.213*LotFrontage+0.166*LotArea+0.228 * MasVnrArea+ 0.180*BsmtFinSF1+……

Loadings:

	Comp 1	Comp 2	Comp 3	Comp 4	Comp 5	Comp 6
LotFrontage	0.213	-0.283	-0.234	0.104		0.240
LotArea	0.166	-0.144	-0.138	0.314	-0.161	0.105
MasVnrArea	0.228	0.162		-0.191		
BsmtFinSF1	0.180	0.249	-0.398	0.188		0.237
BsmtFinSF2			-0.108	0.313	-0.312	0.144
BsmtUnfSF	0.112	-0.102	0.153		0.128	-0.449
TotalBsmtSF	0.299	0.146	-0.302	0.210		-0.154
`1stFlrSF`	0.308		-0.309	0.287		-0.144
`2ndFlrSF`	0.154	-0.228	0.557	-0.183		0.257
LowQualFinSF		-0.126	0.106	0.149	-0.343	
GrLivArea	0.356	-0.193	0.247			0.115
BsmtFullBath	0.101	0.233	-0.365	0.238		0.281
BsmtHalfBath						0.163
FullBath	0.269		0.263		0.279	-0.368
HalfBath	0.124		0.344	-0.455	-0.111	0.441
BedroomAbvGr	0.150	-0.542	0.184	-0.217	-0.220	
KitchenAbvGr		-0.498	-0.168	-0.108	0.459	-0.252
TotRmsAbvGrd	0.295	-0.361	0.255		0.192	0.136
Fireplaces	0.224				-0.500	0.105
GarageCars	0.301	0.139			0.223	-0.244
GarageArea	0.304	0.123		-0.116		-0.334
WoodDeckSF	0.154	0.176		-0.194	-0.152	
OpenPorchSF	0.179			-0.371		0.236
EnclosedPorch		-0.170	0.141	0.374	-0.494	-0.135
`3SsnPorch`						-0.102
ScreenPorch					-0.238	0.257
PoolArea		-0.209	-0.138	0.150	-0.282	0.322
MiscVal		-0.110		0.183	-0.228	0.154

Composante 1 – Taille globale du logement : Elle regroupe les variables liées à la surface et à la capacité du logement (surface habitable, surface du garage, nombre de pièces, sous-sol). Elle représente donc **la dimension globale et la taille du bien**.

Composante 2 – Organisation des pièces principales : Elle oppose le nombre de chambres et de cuisines aux caractéristiques du sous-sol, ce qui traduit **la configuration intérieure et la répartition des pièces principales**.

Composante 3 – Répartition de la surface entre les niveaux : Elle reflète **la distribution de la surface entre le deuxième étage et le sous-sol**.

Composante 4 – Équipements de confort : Elle est liée à des éléments comme **la cheminée et le porche**, représentant certains **équipements de confort du logement**.

Composante 5 – Équipements supplémentaires : Elle met en avant **les salles de bain supplémentaires et la présence d'une piscine**, indiquant des **équipements additionnels du logement**.

Composante 6 – Équipements secondaires : Elle est associée à **des équipements moins fréquents**, comme une demi-salle de bain au sous-sol ou un porche trois saisons.

Régression PLS

Principe de la PLS : La méthode PLS construit des composantes latentes qui maximisent la co**variance des covariables et la variable réponse**, ce qui permet d'intégrer directement l'information de la variable cible lors de la construction des composantes (contrairement à la PCR).

Choix du nombre optimal de composantes : Le nombre de composantes est déterminé par **validation croisée à 10 sous-échantillons**, en retenant celui qui **minimise le PRESS (Predicted Residual Sum of Squares)**.

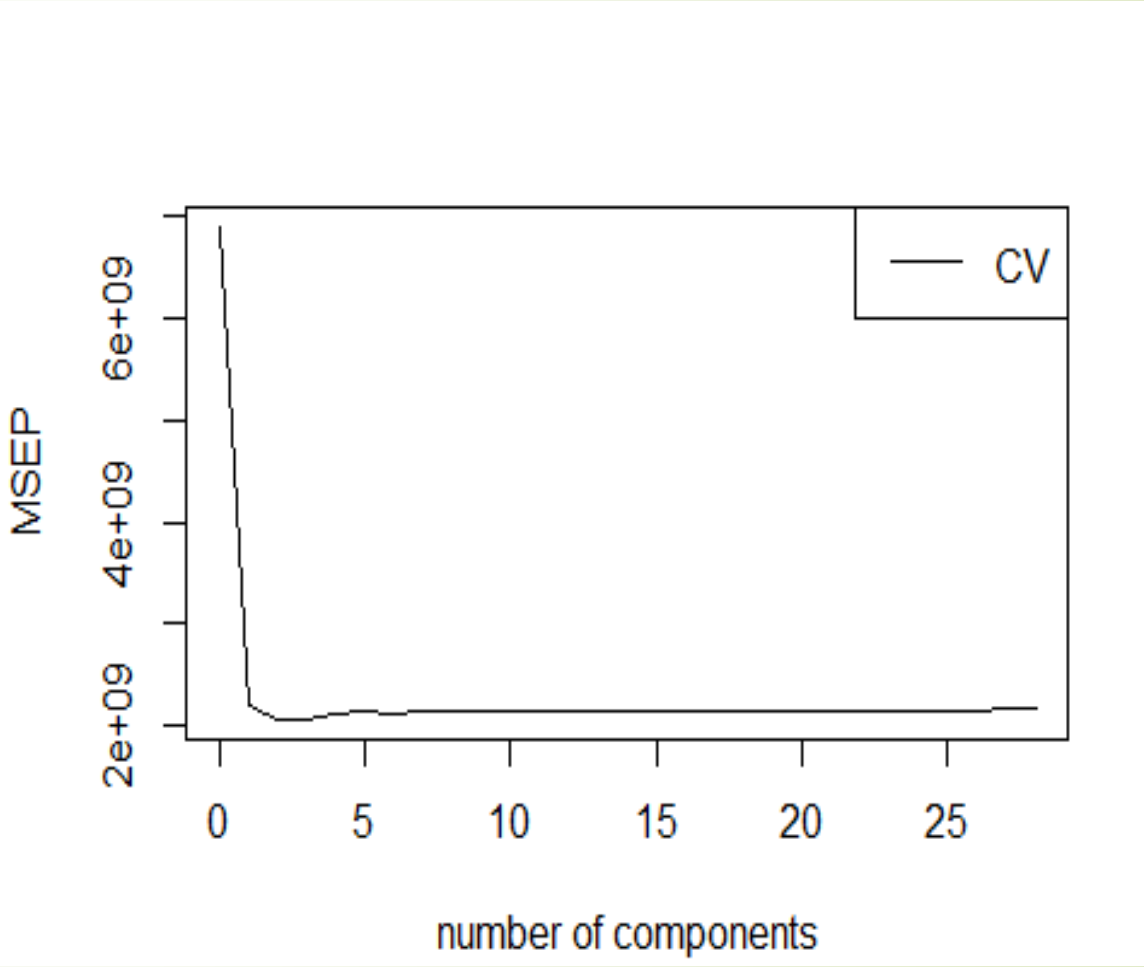

Résultats de la PLS

```
Data:   X dimension: 1121 28
        Y dimension: 1121 1
Fit method: kernelpls
Number of components considered: 3
TRAINING: % variance explained
          1 comps  2 comps  3 comps
X           21.15    27.51    35.44
SalePrice   69.87    74.02    74.80
```

- La première composante explique **21,15 %** de la variance des covariables, tandis que **les trois premières composantes expliquent environ 35,44 %** de cette variance.
- La première composante explique déjà **69,87 % de la variance de la variable dépendante (SalePrice)**, et l'ajout des autres composantes n'augmente que légèrement cette proportion à **74,80 %**, montrant que l'essentiel de l'information prédictive est concentré dans les premières composantes.

Interprétation des loadings et Weights

Pour les Loadings par exemple :

- **LotFrontage= 0.213*T1 - 0.283*T2 - 0.234*T3**, avec les T1,T2,T3 qui représentes les 3 composantes principales retenues.

Loadings:

	Comp 1	Comp 2	Comp 3
LotFrontage	0.213	-0.283	-0.234
LotArea	0.166	-0.144	-0.138
MasVnrArea	0.228	0.162	
BsmtFinSF1	0.180	0.249	-0.398
BsmtFinSF2			-0.108
BsmtUnfSF	0.112	-0.102	0.153
TotalBsmtSF	0.299	0.146	-0.302
`1stFlrSF`	0.308		-0.309
`2ndFlrSF`	0.154	-0.228	0.557
LowQualFinSF		-0.126	0.106
GrLivArea	0.356	-0.193	0.247
BsmtFullBath	0.101	0.233	-0.365
BsmtHalfBath			
FullBath	0.269		0.263
HalfBath	0.124		0.344
BedroomAbvGr	0.150	-0.542	0.184
KitchenAbvGr		-0.498	-0.168
TotRmsAbvGrd	0.295	-0.361	0.255
Fireplaces	0.224		
GarageCars	0.301	0.139	
GarageArea	0.304	0.123	
WoodDeckSF	0.154	0.176	
OpenPorchSF	0.179		
EnclosedPorch		-0.170	0.141
`3SsnPorch`			
ScreenPorch			
PoolArea		-0.209	-0.138
MiscVal		-0.110	

Interprétation des Weights

Les weights, représentent la contribution des covariables à la la formation de la composante. On a donc :

- **T1=0.170*LotFrontage+0.149*LotArea+0.242*MasVnrArea+ 0.193*BsmtFinSF1+……**
- -Composante 1 : GrLivArea((surface habitable hors sous-sol **,0.349**), GarageCars(capacité du garage,**0.320),**GarageArea**(**superficie du garage ,**0.307),** TotalBsmtSF **(0.305),**1stF1rSF **(**superficie totale du sous-sol**, 0.301).**
- -Composante 2 : KitchenAbvGr (**-0.572**),BedroomAbvGr (nombre de chambres au-dessus du sous-sol,**-0.549**),PoolArea (superficie de la piscine,**-0.245**),TotRmsAbvGrd (total de pièces hors sous-sol ,**-0.197**),LotFrontage (longueur de façade donnant sur la rue, **-0.349**)
- -Composante 3 : 2ndFlrSF (**0.459**),TotRmsAbvGrd (**0.354**),FullBath (**0.306**),GrLivArea (**0.293**),BsmtFinSF1 **(-0.306**),GarageArea **(-0.216**),TotalBsmtSF **(-0.212**)

LotArea	0.149	-0.143	
MasVnrArea	0.242	0.111	-0.109
BsmtFinSF1	0.193	0.108	-0.306
BsmtFinSF2			
BsmtUnfSF	0.106		0.105
TotalBsmtSF	0.305		-0.212
`1stFlrSF`	0.301		-0.137
`2ndFlrSF`	0.152		0.459
LowQualFinSF			0.123
GrLivArea	0.349		0.293
BsmtFullBath	0.117	0.136	-0.210
BsmtHalfBath			
FullBath	0.281		0.306
HalfBath	0.133		
BedroomAbvGr		-0.549	
KitchenAbvGr		-0.572	-0.160
TotRmsAbvGrd	0.271	-0.197	0.354
Fireplaces	0.229		
GarageCars	0.320	0.156	
GarageArea	0.307		-0.216
WoodDeckSF	0.167	0.106	-0.151
OpenPorchSF	0.170		-0.209
EnclosedPorch			0.232
`3SsnPorch`			
ScreenPorch			
PoolArea		-0.245	
MiscVal			

Coefficients des trois régressions

Variable	Linéaire	PCR (6 comps)	PLS (3 comps)
LotFrontage	-12.69	-378.92	-1362.90
LotArea	0.37	3152.91	2190.08
MasVnrArea	39.21	7098.68	8663.91
BsmtFinSF1	31.01	5820.11	5984.06
BsmtFinSF2	17.93	-184.07	-928.45
BsmtUnfSF	24.95	2528.58	2959.88
TotalBsmtSF	-	8606.43	8950.89
1stFlrSF	49.39	9380.43	7590.85
2ndFlrSF	42.20	8072.67	7025.39
LowQualFinSF	8.99	-777.40	-472.33
GrLivArea	-	13615.01	11442.69
BsmtFullBath	12786.09	6773.78	4659.36
BsmtHalfBath	5825.99	1543.34	126.22
FullBath	23170.45	13367.89	11948.50
HalfBath	6570.88	3664.95	5900.79
BedroomAbvGr	-16020.77	-12386.41	-6659.10
KitchenAbvGr	-68071.23	-13848.16	-12538.10
TotRmsAbvGrd	8002.30	11895.33	7077.26
Fireplaces	7351.21	4533.62	7462.17
GarageCars	26072.45	14775.91	12656.50
GarageArea	10.43	3882.90	8581.11
WoodDeckSF	35.01	3974.08	6025.74
OpenPorchSF	14.15	558.47	2852.53
EnclosedPorch	-24.91	-1948.49	-2074.41
3SsnPorch	26.34	604.46	1107.56
ScreenPorch	50.05	2966.83	2428.83
PoolArea	-71.74	-3075.08	-3099.66
MiscVal	-3.97	-623.76	-1307.51

Conclusion

- **Les analyses descriptives et la modélisation montrent que les surfaces habitables, le sous-sol, le garage et les pièces d'eau sont les facteurs les plus déterminants du prix immobilier**, tandis que certaines variables comme *LotFrontage* ou *MiscVal* ont peu d'impact. La forte corrélation entre plusieurs variables confirme la présence de multicolinéarité dans les données.
- **La comparaison des modèles (régression linéaire, PCR, PLS) montre que les méthodes sur composantes latentes gèrent mieux la multicolinéarité et concentrent l'essentiel de l'information prédictive dans les premières composantes**, même si la régression linéaire classique offre déjà de bonnes performances. L'ensemble permet d'obtenir une modélisation fiable du prix de vente.

Merci pour votre attention