

UNIVERSITÉ D'ANGERS

MASTER MATHÉMATIQUES ET APPLICATIONS

M1 DATA SCIENCE

ANNÉE ACADÉMIQUE 2025-2026

TRAVAIL ENCADRÉ DE RECHERCHE

Analyse de valeurs extrêmes

Etudiants :

Carmel AWANDE
Yves GNONHOUE

Tuteur Enseignant :

Pr Gilles STUPFLER

Résumé

La théorie des valeurs extrêmes (TVE) constitue un cadre statistique indispensable pour modéliser et estimer la probabilité d'occurrence d'événements rares et de forte intensité. Alors que les approches statistiques traditionnelles se focalisent sur l'estimation de la moyenne conditionnelle et tendent à écarter ces observations jugées “aberrantes”, la TVE permet de décrire l'inhabituel au-delà des observations disponibles.

Ce travail présente les fondements théoriques des deux grandes approches de la TVE : la méthode des maxima de blocs, régie par le théorème de Fisher-Tippett-Gnedenko et modélisée par la loi Généralisée des Valeurs Extrêmes (GEV), ainsi que la méthode des dépassements de seuil (*Peaks-Over-Threshold*, POT), fondée sur le théorème de Pickands-Balkema-de Haan et modélisée par la distribution de Pareto généralisée (GPD). Nous abordons en détail les problématiques d'estimation des paramètres par des méthodes paramétriques (maximum de vraisemblance, méthode des moments) et semi-paramétriques (estimateur de Hill). Une attention particulière est accordée aux diagnostics graphiques indispensables en pratique, tels que le *Mean Excess Plot* pour la sélection optimale du seuil et le *Hill Plot* pour la recherche d'un plateau de stabilité, illustrant le compromis fondamental entre le biais et la variance.

Enfin, l'ensemble de ces méthodologies est mis en œuvre à travers une application concrète sur des données hydrologiques réelles. Les données exploitées correspondent aux débits moyens journaliers de la Loire à Saumur, observés sur la période allant du 1^{er} janvier 1980 au 31 mars 2026.

Mots-clés : Théorie des valeurs extrêmes (TVE), Événements rares, loi Généralisée des Valeurs Extrêmes (GEV), distribution de Pareto généralisée (GPD), Estimateur de Hill, hydrologie.

Engagement de non plagiat

Nous, soussignés **Carmel AWANDE** et **Yves GNONHOUE**, déclarons être pleinement conscients que le plagiat de documents ou d'une partie d'un document publiés sur toutes formes de support, y compris l'internet, constitue une violation des droits d'auteur ainsi qu'une fraude caractérisée. En conséquence, nous nous engageons à à citer toutes les sources que nous avons utilisés utilisées pour écrire ce rapport.

Signature :

Table des matières

1	Introduction	1
1.1	Problématique	1
2	Cadre théorique et rappels statistiques	2
2.1	Fonction de survie	2
2.2	Quantiles et queues de distribution	2
2.3	Notion de domaine d'attraction	3
2.4	Distributions à queue lourde	3
2.4.1	Événements rares et notions de risque	4
2.4.1.1	La probabilité de dépassement	4
2.4.1.2	La période de retour	5
2.4.1.3	Le risque de queue (Tail Risk)	5
2.5	Limites des approches classiques et intérêts de la théorie des valeurs extrêmes . .	5
3	Théorie des valeurs extrêmes	6
3.1	Loi des maxima (théorème de Fisher–Tippett–Gnedenko)	6
3.1.1	Loi Généralisée des Valeurs Extrême (GEV)	7
3.2	Modèle des excès (Pickands–Balkema–de Haan)	8
3.2.1	Distribution de Pareto généralisée (GPD)	9
3.3	Choix du seuil	10
3.3.1	Choix du seuil : Application et compromis	10
3.3.2	Analyse du compromis Biais-Variance	11
4	Estimation des paramètres extrêmes	12
4.1	Estimation des paramètres de la GEV et GPD	12
4.1.1	Méthodes paramétriques	12
4.1.1.1	Maximum de vraisemblance	12
4.1.1.2	Méthode des moments	14
4.1.2	Méthodes semi-paramétriques	15
4.1.2.1	Estimateur de Hill	15
4.1.2.2	Choix du paramètre k et graphique de Hill	15
4.1.2.3	Aide à l'interprétation : le Mean Excess Plot (ME-plot)	16
4.2	Estimation des quantiles extrêmes	18
4.2.1	Estimation des quantiles extrêmes : de la théorie à la pratique	19
4.2.1.1	Fondements théoriques et comportement asymptotique	19
4.2.1.2	Estimation par inversion de la fonction empirique	19
4.2.2	Niveau de retour	19
4.2.3	Intervalles de confiance	20

5	Application sur données réelles	21
5.1	Présentation des données	21
5.1.1	Nettoyage et exploration	21
5.2	Mise en œuvre des modèles paramétriques et non paramétriques	23
5.2.1	Estimation des paramètres GEV et GPD	23
5.2.1.1	Estimation des paramètres de GEV	23
5.2.1.2	Estimation des paramètres de GPD	24
5.2.2	Estimation par la méthode semi paramétriques de Hill	26
5.2.3	Estimation des quantiles de retour	27
5.2.3.1	Estimation des quantiles de retour pour le modèle GEV	27
5.2.3.2	Estimation des quantiles de retour pour le modèle GPD	28
5.3	Limites et perspectives	29
	Annexes	32
	Annexe 1	32
	Annexe 2	35

Chapitre 1

Introduction

La théorie des valeurs extrêmes (TVE) est une branche de la statistique qui s'intéresse à la modélisation des phénomènes rares c'est-à-dire les événements avec une faible probabilité d'occurrence. Contrairement à la plupart des méthodes statistiques qui se concentrent sur les caractéristiques moyennes des données, la théorie des valeurs extrêmes vise à modéliser les phénomènes rares qui peuvent avoir un impact majeur. Comme le souligne la littérature, « cette discipline remonte au début du XX^e siècle et a évolué pour devenir un cadre méthodologique robuste permettant de décrire "l'inhabituel" plutôt que "l'habituel" » [2].

Dans de nombreux domaines (hydrologie, météorologie, finances, assurance, sciences sociales, etc.), l'enjeu ne réside pas dans l'étude de la moyenne, mais dans l'analyse des valeurs extrêmes. On entend par valeurs extrêmes des observations se situant à une distance significative de l'ensemble des autres observations dans un jeu de données. Souvent ces observations sont considérées comme aberrantes et sont ignorées pour la plupart du temps car en statistique classique, comme l'on s'intéresse le plus souvent à l'estimation de la moyenne conditionnelle (en régression par exemple), la présence de ces dernières biaise le plus souvent les estimations réalisées. Or, dans certaines problématiques, il peut s'avérer utile de comprendre la distribution de celles-ci. Face à de tels événements, les approches statistiques classiques fondées sur de grands échantillons et des modèles centrés sur l'estimation de la moyenne conditionnelle s'avèrent insuffisantes. La théorie des valeurs extrêmes fournit alors un cadre adapté, permettant d'estimer et de modéliser ces événements rares, y compris au-delà des observations disponibles.

L'objectif de ce projet est de comprendre les bases de la théorie des valeurs extrêmes, qui est le cadre statistique adapté à la considération de ce type d'applications. On décrira les modèles classiques du cadre des valeurs extrêmes, qui permettront d'aborder la question de l'estimation de paramètres extrêmes d'une distribution. Une application de ces diverses méthodes dans un contexte hydrologique sera présentée afin d'illustrer comment la théorie des valeurs extrêmes s'utilise en pratique et quelles sont ses limitations.

1.1 Problématique

La question principale est comment modéliser et estimer les événements rares à partir des observations disponibles, sachant que ces événements se produisent peu fréquemment et apparaissent très rarement dans les jeux de données ?

Chapitre 2

Cadre théorique et rappels statistiques

2.1 Fonction de survie

Définition 1 (Fonction de survie). Soit X une variable aléatoire réelle de fonction de répartition F . On appelle **fonction de survie** de X , notée $\bar{F}$, l'application définie par :

$$\forall x \in \mathbb{R}, \quad \bar{F}(x) = P_X([x, +\infty[) = P(X > x) = 1 - F(x)$$

2.2 Quantiles et queues de distribution

Définition 2. (Notion de statistiques d'ordre) On appelle statistique d'ordre d'un échantillon $(X_1, \dots, X_n)$ le réarrangement dans l'ordre croissant des valeurs de l'échantillon, noté Pour

$$(X_{1:n}, X_{2:n}, \dots, X_{n:n})$$

de sorte que

$$X_{1:n} \leq X_{2:n} \leq \dots \leq X_{n:n}.$$

Les statistiques d'ordre extrêmes correspondent aux valeurs extrêmes de l'échantillon, c'est-à-dire au minimum et au maximum :

$$X_{1:n} = \min(X_1, X_2, \dots, X_n), \quad X_{n:n} = \max(X_1, X_2, \dots, X_n).$$

Proposition 1. Soit $X_1, \dots, X_n$ une suite de variables aléatoires i.i.d. de fonction de répartition F . Alors, pour tout $x \in \mathbb{R}$,

$$P(X_{n:n} \leq x) = [F(x)]^n.$$

Les variables $X_{1:n}$ et $X_{n:n}$ ont respectivement pour fonctions de répartition

$$P(X_{n:n} \leq x) = [F(x)]^n \quad \text{et} \quad P(X_{1:n} \leq x) = 1 - [1 - F(x)]^n.$$

Démonstration. Pour $X_{n:n} = \max(X_1, \dots, X_n)$, on a

$$\begin{aligned} P(X_{n:n} \leq x) &= P(\max(X_1, \dots, X_n) \leq x) \\ &= P(X_1 \leq x, \dots, X_n \leq x). \end{aligned}$$

Comme les variables $X_1, \dots, X_n$ sont indépendantes, on obtient

$$P(X_{n:n} \leq x) = [F(x)]^n.$$

Pour $X_{1:n} = \min(X_1, \dots, X_n)$, on a :

$$\begin{aligned} P(X_{1:n} > x) &= P(X_1 > x, \dots, X_n > x) \\ &= P(X_1 > x) \cdot \dots \cdot P(X_n > x) \\ &= [1 - F(x)]^n. \end{aligned}$$

On peut donc en déduire la fonction de répartition du minimum :

$$P(X_{1:n} \leq x) = 1 - [1 - F(x)]^n.$$

□

Définition 3 (Quantile d'une variable aléatoire). Soit X une variable aléatoire réelle de fonction de répartition F . fonction quantile $q_X : [0, 1] \rightarrow \mathbb{R}$ est définie par

$$q_X(\alpha) = \inf\{x \in \mathbb{R} \mid F(x) \geq \alpha\}, \quad \alpha \in [0, 1].$$

Le réel $q_X(\alpha)$ est appelé **quantile d'ordre** α de la loi de X .

2.3 Notion de domaine d'attraction

Définition 4 (Domaine d'attraction). Soit $X_1, \dots, X_n$ une suite de variables aléatoires i.i.d. de fonction de répartition F , et soit

$$X_{n:n} = \max(X_1, \dots, X_n).$$

On dit que F appartient au **domaine d'attraction** d'une fonction de répartition G s'il existe des suites de constantes $(a_n)_{n \geq 1}$ avec $a_n > 0$ et $(b_n)_{n \geq 1}$ telles que

$$P\left(\frac{X_{n:n} - b_n}{a_n} \leq x\right) \longrightarrow G(x), \quad \text{lorsque } n \rightarrow \infty.$$

2.4 Distributions à queue lourde

Définition 5 (Distribution à queue lourde et Kurtosis). Soit X une variable aléatoire de distribution F . Si le kurtosis (moment centré d'ordre 4 normalisé par le carré du moment d'ordre 2) satisfait :

$$\text{Kurtosis} = \frac{\mathbb{E}[(X - \mu)^4]}{(\mathbb{E}[(X - \mu)^2])^2} > 3,$$

où $\mu = \mathbb{E}[X]$, alors on considère que la distribution F est à *queue lourde*.

Autrement dit, une distribution est à queue lourde si ses valeurs extrêmes ont une probabilité plus élevée que dans une loi normale. «Une distribution est à queue lourde si son coefficient d'asymétrie (skewness) est supérieur à celui de la distribution normale »[3].

Analyse des queues de distribution

La loi Normale (rouge) s'écrase alors que la Fréchet (bleue) persiste




FIGURE 2.1 – Comparaison entre une queue dégénérée (Normale) et une queue lourde (Fréchet) avec zoom sur la zone d'intérêt.

Remarque 1. Le **Kurtosis** (ou coefficient d'aplatissement) permet de mesurer la concentration des observations dans les queues de la distribution par rapport au centre.

- Pour une **loi Normale**, le Kurtosis est exactement égal à 3. C'est notre point de référence (distribution mésokurtique¹).
- Une distribution est dite à **queue lourde** (ou leptokurtique) si son **Kurtosis est supérieur à 3**.

Dans ce dernier cas, la probabilité d'observer des événements extrêmes est plus élevée que dans le cadre gaussien, ce qui se traduit visuellement par une courbe qui décroît plus lentement vers zéro (voir Figure 2.1).

2.4.1 Événements rares et notions de risque

L'objectif principal de la Théorie des Valeurs Extrêmes est de quantifier la probabilité d'occurrence d'événements situés dans la queue de distribution, qualifiés d'**événements rares**. En hydrologie, ces événements correspondent aux scénarios de risque majeur tels que les crues exceptionnelles.

2.4.1.1 La probabilité de dépassement

Le risque est souvent défini par la probabilité qu'une variable aléatoire X dépasse un seuil critique u très élevé. Cette probabilité est directement donnée par la fonction de survie définie précédemment :

$$\text{Risque}(u) = P(X > u) = \bar{F}(u)$$

1. Une distribution mésokurtique est une distribution dont l'épaisseur des queues est identique à celle d'une loi normale, servant de point d'équilibre entre les queues fines et les queues lourdes.

Lorsque u tend vers l'infini, cette probabilité devient très faible, mais l'impact de l'événement augmente de manière critique. C'est ici que la forme de la queue de distribution devient déterminante.

2.4.1.2 La période de retour

La notion de risque est intimement liée à la **période de retour** (T). Si un événement a une probabilité p de se produire chaque année, sa période de retour moyenne T est définie par :

$$T = \frac{1}{p} = \frac{1}{1 - F(u)}$$

Par exemple en hydrologie, une valeur de crue qui correspond au quantile $q(0,99)$ a une probabilité de dépassement de 0,01, ce qui équivaut à une période de retour de 100 ans. On parle alors de **crue centennale**.

2.4.1.3 Le risque de queue (Tail Risk)

On distingue deux types de comportements fondamentaux pour le risque :

- **Queue légère** : Le risque diminue de façon exponentielle. Les événements extrêmes sont très peu probables au-delà d'un certain seuil.
- **Queue lourde** : Le risque diminue selon une loi de puissance ($x^{-\alpha}$). Les événements extrêmes sont alors **plus fréquents** et **plus intenses**, ce qui nécessite des modèles spécifiques comme la loi GEV ou GPD.

2.5 Limites des approches classiques et intérêts de la théorie des valeurs extrêmes

Les distributions à queue lourde ont souvent des moments d'ordre 1 ou 2 qui ne sont pas finis (ou n'existent pas). Dans ces cas, le TCL par exemple, devient inapplicable et la théorie statistique classique, la plupart du temps basée sur des approximations par la distribution normale, n'est plus appropriée. Que faire donc dans ces conditions ?

Il faut donc faire recours à des méthodes spécifiques pour les distributions à queue lourde, souvent caractéristiques des valeurs extrêmes (valeurs extrêmes plus fréquentes que dans ces types de distributions que la loi normale). C'est là qu'intervient la TVE qui trouve un intérêt majeur dans certaines situations où ces valeurs extrêmes présentent un intérêt, fournissant ainsi toute une théorie permettant la modélisation des événements rares.

Chapitre 3

Théorie des valeurs extrêmes

Dans ce chapitre, nous présenterons les méthodes permettant d'estimer l'indice de queue ξ et le paramètre d'échelle σ à partir d'un échantillon fini. L'enjeu de l'inférence dans le cadre des valeurs extrêmes réside dans la rareté des données : par définition, les événements extrêmes se situent dans la queue de distribution, là où les observations sont les moins nombreuses.

3.1 Loi des maxima (théorème de Fisher–Tippett–Gnedenko)

Intéressons nous au comportement asymptotique de la distribution du maximum $(X_{n:n})$. On rappelle que $X_{n:n} = \max(X_1, X_2, \dots, X_n)$ et d'après la proposition 1 on a :

$$P(X_{n:n} \leq x) = [F(x)]^n.$$

Ainsi, on a :

$$F_{X_{n:n}}(x) = \lim_{n \rightarrow \infty} (F(x))^n = \begin{cases} 0 & \text{si } F(x) < 1 \\ 1 & \text{si } F(x) = 1 \end{cases} \quad (3.1)$$

On remarque donc que la loi du maximum tend vers une constante, la distribution est donc dégénérée (c'est-à-dire qu'elle se concentre autour d'une seule valeur). Cela offre donc peu d'informations sur son comportement asymptotique. La loi faible des grands nombres (LFGN), par exemple, stipule une convergence en probabilité de la moyenne empirique vers la moyenne théorique. La distribution de la moyenne empirique est donc dégénérée. Le théorème central limite (TCL) résout donc le problème par une normalisation linéaire définie comme suit :

$$\Pr \left(\overline{X}_n \leq \sigma_n x + m_n \right) \longrightarrow \Phi(x) \quad \text{quand } n \rightarrow \infty, \quad (3.2)$$

où

$$m_n = \mathbb{E}(\overline{X}_n) = \mathbb{E}(X_1), \quad \sigma_n^2 = \text{Var}(\overline{X}_n) = \frac{\text{Var}(X_1)}{n},$$

Φ est la fonction de distribution de la loi normale centrée et réduite. De façon analogue au TCL pour corriger le problème de loi dégénérée de la loi du maximum, et obtenir une distribution plus informative, Fisher et Tippett ont proposé une normalisation afin d'obtenir une distribution non dégénérée.

Théorème 1. (Théorème de Fisher-Tippett [4]-Gnedenko [5]) Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires i.i.d. avec fonction de répartition F . S'il existe deux suites normalisantes

$(a_n)_{n \geq 1}$, $a_n > 0$, et $(b_n)_{n \geq 1}$ ($b_n \in \mathbb{R}$) telles que la loi du maximum normalisé converge vers une loi H_ξ , alors :

$$\lim_{n \rightarrow \infty} P \left(\frac{X_{n:n} - b_n}{a_n} \leq x \right) = \lim_{n \rightarrow \infty} F^n(a_n x + b_n) = H_\xi(x), \quad x \in \mathbb{R} \quad (3.3)$$

où :

- a_n est un paramètre de position,
- b_n est un paramètre d'échelle,
- ξ est un paramètre de forme.
- H_ξ est la fonction de répartition limite et est non dégénérée.

H_ξ prend l'une des formes suivantes :

- **Loi de Gumbel** : Support $\mathbb{R}$

$$\Lambda(x) = \exp(-\exp(-x)), \quad x \in \mathbb{R} \quad (3.4)$$

- **Loi de Fréchet** Support $\left] \mu - \frac{\sigma}{\xi}, +\infty \right[$

$$\phi_\alpha(x) = \begin{cases} 0, & x \leq 0, \\ \exp(-x^{-\alpha}), & x > 0, \alpha > 0 \end{cases} \quad (3.5)$$

- **Loi de Weibull** : Support $\left] -\infty, \mu - \frac{\sigma}{\xi} \right[$

$$\psi_\alpha(x) = \begin{cases} \exp(-(-x)^\alpha), & x \leq 0, \\ 1, & x > 0, \alpha > 0 \end{cases} \quad (3.6)$$

Ces trois distributions sont appelées loi des valeurs extrêmes

3.1.1 Loi Généralisée des Valeurs Extrême (GEV)

Il est possible d'unifier les trois distributions précédentes (Gumbel, Fréchet, Weibull) en une seule famille appelée **distribution des valeurs extrêmes généralisées** $GEV(\mu, \sigma, \xi)$, proposée par von Mises (1954) et Jenkinson (1955) de la façon suivante :

$$GEV(\mu, \sigma, \xi) = \begin{cases} \exp\left(-[1 + \xi(\frac{x-\mu}{\sigma})]_+^{-1/\xi}\right), & \xi \neq 0, \\ \exp\left(-\exp(-\frac{x-\mu}{\sigma})\right), & \xi = 0 \end{cases} \quad (3.7)$$

où $x_+ = \max(x, 0)$

$$h(\mu, \sigma, \xi, x) = \exp\left(-\left(1 + \xi \frac{x-\mu}{\sigma}\right)^{-\frac{1}{\xi}}\right) \times \left(\left(1 + \xi \frac{x-\mu}{\sigma}\right)^{-\frac{1}{\xi-1}}\right) \quad (3.8)$$

$$L(\theta, Y) = \prod_{i=1}^n h(\theta, Y_i) \mathbf{1}_{\{1 + \xi \frac{Y_i - \mu}{\sigma} > 0\}} \quad (3.9)$$

Le paramètre ξ caractérise selon sa valeur le comportement des queues de distributions. Ainsi, si :

- La distribution de Gumbel correspond à $\xi = 0$: $\text{GEV}(0, 1, 0) = \text{Gumbel}$;
- La distribution de Fréchet correspond à $\xi > 0$: $\text{GEV}(1, \xi^{-1}, \xi^{-1}) = \text{Fréchet}(\xi)$;
- La distribution de Weibull correspond à $\xi < 0$: $\text{GEV}(-1, \xi^{-1}, -\xi^{-1}) = \text{Weibull}(\xi)$.




FIGURE 3.1 – Comparaison des densités des distributions de Gumbel ($\xi = 0$), Fréchet ($\xi = 0.5$) et Weibull ($\xi = -0.5$)

Cette méthode présente certaines limites importantes dans son application. Son principal inconvénient est la perte d'information qu'elle induit, puisqu'on ne conserve que les maxima observés sur des blocs prédéfinis (par exemple annuels ou mensuels), en négligeant l'ensemble des autres observations. Cette réduction de l'échantillon conduit généralement à une augmentation de l'incertitude sur les estimations et à une plus grande instabilité des paramètres, en particulier lorsque la taille des blocs est importante et que le nombre de maxima disponibles devient faible. Enfin, la méthode repose sur l'hypothèse d'indépendance des maxima entre blocs, hypothèse qui peut être violée en pratique dans de nombreuses applications comme l'hydrologie ou la finance.

3.2 Modèle des excès (Pickands–Balkema–de Haan)

En théorie des valeurs extrêmes, l'idée centrale repose sur l'étude de la distribution des maxima (valeurs les plus extrêmes de la distribution) pour la modélisation des événements rares. On peut s'intéresser non pas aux maxima mais plutôt à des valeurs précises dépassant un seuil prédéfini par exemple et se concentrer uniquement sur les observations dépassant ce seuil. Cette approche est nommée **la méthode des dépassements de seuil** ou en anglais **Peaks-Over-Threshold (POT)**. Cette méthode a l'avantage de prendre en compte beaucoup plus de données que la théorie des valeurs extrêmes basée sur les maxima, ce qui peut donc fournir des estimations plus précises.

Définition 6. L'excès au-dessus d'un seuil u comme un ensemble de variables aléatoires conditionnelles :

$$Y = X - u \mid X > u.$$

À partir de la fonction de répartition F de X , on cherche à déterminer la distribution conditionnelle F_u associée aux variables aléatoires dépassant ce seuil u prédéfini.

Définition 7. On appelle distribution des excès de la variable aléatoire X par rapport à un seuil u la loi de probabilité de la variable aléatoire Y , représentant l'excès de X au-delà du seuil u , donnée par sa fonction de répartition F_u :

$$\forall y \in \mathbb{R}, \quad F_u(y) = P(X - u \leq y \mid X > u) = \begin{cases} 0 & \text{si } y \leq 0, \\ 1 - \frac{1 - F(u + y)}{1 - F(u)} & \text{si } 0 < y < x_F - u, \\ 1 & \text{si } y \geq x_F - u. \end{cases}$$

Remarque 2. Le point x_F désigne le point terminal supérieur de la distribution F , défini formellement par :

$$x_F = \sup\{x \in \mathbb{R} : F(x) < 1\}$$

Si $x_F = +\infty$, on dit que la distribution a un support non borné à droite.

Théorème 2. (Théorème de Pickands–Balkema–de Haan) *Le fondement théorique de la méthode POT repose sur le théorème de Pickands–Balkema–de Haan qui stipule que la distribution des excès au-dessus d'un seuil élevé u converge vers une distribution de Pareto généralisée (GPD) lorsque u devient grand. C'est à dire :*

$$\mathbb{P}(X - u \leq y \mid X > u) \approx G_{\xi, \beta}(y) \quad (3.10)$$

3.2.1 Distribution de Pareto généralisée (GPD)

La distribution limite des excès est la distribution de Pareto généralisée (GPD), définie par :

Fonction de densité Pour tout $x > 0$, la densité s'écrit :

$$g_{\xi, \sigma}(x) = \begin{cases} \frac{1}{\sigma} \left(1 + \xi\left(\frac{x}{\sigma}\right)\right)^{-\frac{1}{\xi}-1}, & \text{si } 1 + \xi\left(\frac{x}{\sigma}\right) > 0, \xi \neq 0, \\ \frac{1}{\sigma} \exp\left(-\frac{x}{\sigma}\right), & \text{si } x > 0, \xi = 0. \end{cases}$$

Fonction de répartition

$$G_{\xi, \sigma}(x) = \begin{cases} 1 - \left(1 + \xi\left(\frac{x}{\sigma}\right)\right)^{-1/\xi} & \text{si } \xi \neq 0, \\ 1 - \exp\left(-\frac{x}{\sigma}\right) & \text{si } \xi = 0. \end{cases}$$

Paramètres et support

- ξ : paramètre de forme (indice de queue),
- $\sigma > 0$: paramètre d'échelle,
- avec le support défini par :

$$\begin{cases} x \geq 0 & \text{si } \xi \geq 0, \\ 0 \leq x \leq -\frac{\sigma}{\xi} & \text{si } \xi < 0. \end{cases}$$




FIGURE 3.2 – Comparaison des densités des distributions GPD

3.3 Choix du seuil

En pratique, la sélection d'un seuil optimal dans la méthode POT peut s'avérer délicate car cela a une forte influence sur la qualité du modèle. Un seuil choisi trop bas par exemple pourrait inclure des valeurs non extrêmes et donc biaiser les estimations des paramètres de forme ou d'échelle par exemple. Un seuil très élevé peut avoir pour effet de réduire le nombre d'excès (nombre d'observations au-dessus du seuil fixé) ce qui pourrait augmenter la variance et les écarts-types des différents estimateurs. On peut s'aider de plusieurs graphiques pour décider du seuil optimal, comme par exemple le graphique des QQ-plot qui pourrait permettre de vérifier l'adéquation des excès au-dessus d'un seuil u fixé avec la distribution empirique de Pareto généralisée (GPD). Cependant, une méthode complémentaire et très répandue consiste à utiliser le Mean Excess Plot (ou graphique de l'espérance des excès), qui permet d'identifier visuellement le seuil à partir duquel la distribution présente un comportement linéaire. C'est cette approche que nous allons privilégier pour notre étude pratique sur données simulées.

3.3.1 Choix du seuil : Application et compromis

En pratique, la sélection du seuil u ne repose pas uniquement sur des critères automatiques, mais sur une analyse de stabilité. Pour illustrer cette démarche, nous avons procédé à une simulation d'un échantillon de $n = 1000$ observations suivant une loi de Fréchet (de paramètre de forme $\xi = 0.5$). Ce type de loi est particulièrement adapté pour représenter des phénomènes à queue lourde, comme les débits de crues. Le Mean Excess Plot est construit en calculant, pour chaque seuil u potentiel, la moyenne arithmétique des écarts entre les observations dépassant ce seuil et le seuil lui-même. Toutefois, son utilisation impose une restriction importante : l'instabilité à haut seuil. À mesure que u augmente, le nombre d'observations diminue, ce qui accroît la variance de l'estimateur et produit des oscillations erratiques à droite du graphique (voir Figure 3.2), rendant l'interprétation délicate dans cette zone. Cette étape de diagnostic est le pivot indispensable avant de finaliser l'estimation des paramètres au chapitre suivant.

Comme nous le détaillerons dans l'aide à l'interprétation (Section 4.1.2.3), l'allure de la pente du Mean Excess Plot valide le choix du modèle : une pente positive confirme l'appartenance au domaine de Fréchet ($\xi > 0$), justifiant ainsi l'application de l'estimateur de Hill pour calculer précisément l'indice de queue. Après simulation de ces données, nous obtenons le graphique suivant :




FIGURE 3.3 – Mean Excess Plot (Données simulées - Loi de Fréchet)

3.3.2 Analyse du compromis Biais-Variance

L'interprétation de ce graphique repose sur la recherche d'un **compromis optimal** au sein d'un intervalle de seuils acceptables :

- **Choix d'un seuil trop bas** ($u < 400$) : On remarque que la courbe n'est pas encore parfaitement linéaire. En choisissant un seuil dans cette zone, nous intégrons trop de données issues du *corps* de la distribution. Cela introduit un **biais** important car le modèle GPD tente d'expliquer des valeurs qui ne sont pas réellement extrêmes.
- **Choix d'un seuil trop élevé** ($u > 800$) : À l'inverse, si l'on se place trop loin dans la queue, la zone d'incertitude s'élargit considérablement. Le nombre d'excès devient trop faible pour obtenir des estimations stables. La **variance** de nos estimateurs augmente alors, rendant les prédictions peu fiables.
- **Le compromis** ($u \in [450, 600]$) : C'est dans cet intervalle que la linéarité est la plus manifeste et que l'enveloppe de confiance reste étroite.

En fixant $u = 450$, nous maximisons la taille de l'échantillon d'extrêmes tout en garantissant que le comportement de la moyenne des excès suit la direction rectiligne imposée par la théorie de Pickands-Balkema-de Haan.

Cette méthode a l'avantage de diminuer la perte d'informations par rapport à la méthode de GEV.

Chapitre 4

Estimation des paramètres extrêmes

En théorie des valeurs extrêmes, on s'intéresse particulièrement à l'étude de la queue de distributions. Ainsi pour l'estimation des différents paramètres des différentes distributions, dont un en particulier notamment l'indice des valeurs extrêmes ξ caractérisant le comportement de la queue de distributions plusieurs méthodes existent. Nous ne présenterons que quelques unes de ces méthodes (paramétriques et semi-paramétriques).

4.1 Estimation des paramètres de la GEV et GPD

4.1.1 Méthodes paramétriques

Deux méthodes classiques en statistique sont souvent utilisées pour l'estimation des paramètres de distribution, il s'agit du maximum de vraisemblance et de la méthode des moments.

4.1.1.1 Maximum de vraisemblance

La distribution des valeurs extrêmes généralisée (GEV) est caractérisée par un paramètre de localisation $\mu \in \mathbb{R}$, un paramètre d'échelle $\sigma \in \mathbb{R}_+^*$, et un paramètre de forme $\xi \in \mathbb{R}$. Soit $X_1, \dots, X_n$ un n échantillon de variables aléatoires indépendantes et identiquement distribuées suivant une loi $\text{GEV}(\mu, \sigma, \xi)$. Le modèle GEV n'étant pas régulier dans le cas où le paramètre de forme ξ est non nul (le modèle de Fréchet et celui de Weibull), les propriétés asymptotiques classiques du maximum de vraisemblance (consistant, asymptotiquement efficace et asymptotiquement normal, etc.) ne sont pas satisfaites. Ainsi, d'après les travaux de [10] nous avons les résultats suivants :

- Lorsque $\xi > -0.5$, les estimateurs du maximum de vraisemblance sont réguliers, au sens où ils possèdent les propriétés asymptotiques usuelles.
- Lorsque $-1 < \xi < -0.5$, les estimateurs du maximum de vraisemblance existent généralement, mais n'ont pas les propriétés asymptotiques standards.
- Lorsque $\xi < -1$, les estimateurs du maximum de vraisemblance sont peu susceptibles d'exister.

Rappelons la **distributions des valeurs extrêmes généralisées (GEV)**

$$\text{GEV}(\mu, \sigma, \xi) = \begin{cases} \exp \left(- [1 + \xi(\frac{x-\mu}{\sigma})]_+^{-1/\xi} \right), & \xi \neq 0, \\ \exp \left(- \exp(-\frac{x-\mu}{\sigma}) \right), & \xi = 0 \end{cases} \quad (4.1)$$

où $x_+ = \max(x, 0)$

La fonction de vraisemblance s'écrit comme suit :

$$\ell(\mu, \sigma, \xi) = \prod_{i=1}^n GEV(x_i, \mu, \sigma, \xi) \quad (4.2)$$

En passant à la log-vraisemblance on obtient dans le cas :

$$\ell\ell(\mu, \sigma, \xi) = \log \prod_{i=1}^n GEV(x_i, \mu, \sigma, \xi) = \sum_{i=1}^n \log GEV(x_i, \mu, \sigma, \xi) \quad (4.3)$$

En considérant le cas $\xi \neq 0$, on a

$$\ell\ell(\mu, \sigma, \xi) = -n \log \sigma - \left(1 + \frac{1}{\xi}\right) \sum_{i=1}^n \log \left(1 + \xi \left(\frac{x_i - \mu}{\sigma}\right)\right) - \sum_{i=1}^n \left(1 + \xi \left(\frac{x_i - \mu}{\sigma}\right)\right)^{-1/\xi}$$

sous la condition $1 + \xi \left(\frac{x_i - \mu}{\sigma}\right) > 0$, pour $i = 1, \dots, m$. $\hat{\theta} = (\hat{\mu}, \hat{\sigma}, \hat{\xi})$ est solution du système suivant :

$$\begin{aligned} \hat{\mu} &= \begin{cases} \frac{\partial \ell(\mu, \sigma, \xi)}{\partial \mu} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma, \xi)}{\partial \mu^2} \leq 0 \end{cases} \\ \hat{\sigma} &= \begin{cases} \frac{\partial \ell(\mu, \sigma, \xi)}{\partial \sigma} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma, \xi)}{\partial \sigma^2} \leq 0 \end{cases} \\ \hat{\xi} &= \begin{cases} \frac{\partial \ell(\mu, \sigma, \xi)}{\partial \xi} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma, \xi)}{\partial \xi^2} \leq 0 \end{cases} \end{aligned}$$

En considérant le cas $\xi = 0$, il ne reste que deux paramètres à estimer. Il s'agit alors de la loi de Gumbel.

$$\ell\ell(\mu, \sigma) = -n \log \sigma - \sum_{i=1}^n \left[\frac{x_i - \mu}{\sigma} + \exp \left(-\frac{x_i - \mu}{\sigma} \right) \right].$$

$\hat{\theta} = (\hat{\mu}, \hat{\sigma})$ est solution du système suivant :

$$\begin{aligned} \hat{\mu} &= \begin{cases} \frac{\partial \ell(\mu, \sigma)}{\partial \mu} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma)}{\partial \mu^2} \leq 0 \end{cases} \\ \hat{\sigma} &= \begin{cases} \frac{\partial \ell(\mu, \sigma)}{\partial \sigma} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma)}{\partial \sigma^2} \leq 0 \end{cases} \end{aligned}$$

En pratique, ces diverses équations n'ont pas de solution explicite. On a donc recours à des méthodes numériques d'optimisation pour la résolution, notamment l'algorithme de Newton Raphson. La méthode du maximum de vraisemblance donne des estimateurs asymptotiquement efficaces et convergents sous certaines conditions.

Rappelons **la distribution de Pareto généralisée (GPD)**

$$g_{\xi}(x) = \begin{cases} \frac{1}{\sigma} \left(1 + \xi \left(\frac{x}{\sigma}\right)\right)^{-\frac{1}{\xi}-1}, & \text{si } 1 + \xi \left(\frac{x}{\sigma}\right) > 0, \xi \neq 0, \\ \frac{1}{\sigma} \exp \left(-\frac{x}{\sigma}\right), & \text{si } x > 0, \xi = 0. \end{cases}$$

De façon analogue on obtient la log-vraisemblance suivante pour le cas de la GPD où $\xi \neq 0$:

$$\ell\ell(\sigma, \gamma) = -n \log \sigma - \left(\frac{1}{\xi} + 1 \right) \sum_{i=1}^n \log \left(1 + \xi \frac{y_i}{\sigma} \right),$$

sous la contrainte :

$$1 + \xi \frac{x_i}{\sigma} > 0, \quad \forall i = 1, \dots, n.$$

$$\frac{\partial \ell}{\partial \sigma} = 0 \quad \text{et} \quad \frac{\partial \ell}{\partial \gamma} = 0.$$

$\hat{\theta} = (\hat{\sigma}, \hat{\xi})$ est solution du système suivant :

$$\begin{aligned} \hat{\mu} &= \begin{cases} \frac{\partial \ell(\mu, \sigma, \xi)}{\partial \mu} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma, \xi)}{\partial \mu^2} \leq 0 \end{cases} \\ \hat{\sigma} &= \begin{cases} \frac{\partial \ell(\mu, \sigma, \xi)}{\partial \sigma} = 0 \\ \frac{\partial^2 \ell(\mu, \sigma, \xi)}{\partial \sigma^2} \leq 0 \end{cases} \end{aligned}$$

Le système ci-dessus ne possède pas de solution analytique explicite. Les estimateurs $(\hat{\sigma}, \hat{\gamma})$ sont donc obtenus par des méthodes d'optimisation numérique.

Dans le cas $\gamma = 0$, la loi de Pareto généralisée correspond à une loi exponentielle :

$$f(x) = \frac{1}{\sigma} e^{-x/\sigma}.$$

4.1.1.2 Méthode des moments

Le principe de la méthode consiste à évaluer les moments théoriques à ceux empiriques. Les moments d'ordre 1 et 2 dans le cadre de la GPD sont les suivants :

$$\mathbb{E}[X] = \frac{\sigma}{1 - \xi}, \quad \text{si } \xi < 1.$$

et

$$\text{Var}(X) = \frac{\sigma^2}{(1 - \xi)^2(1 - 2\xi)}, \quad \text{si } \xi < \frac{1}{2}.$$

On obtient alors les expressions suivantes :

$$\xi = \frac{1}{2} \left(1 - \frac{\mathbb{E}(X)^2}{\mathbb{V}(X)} \right) \quad \text{et} \quad \sigma = \frac{\mathbb{E}(X)}{2} \left(1 + \frac{\mathbb{E}(X)^2}{\mathbb{V}(X)} \right).$$

En remplaçant $\mathbb{E}(X)$ et $\mathbb{V}(x)$ par leurs estimateurs empiriques :

$$\bar{X} := \frac{1}{n} \sum_{i=1}^n Y_i \quad \text{et} \quad S^2 := \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2,$$

on obtient les estimateurs des moments de ξ et σ :

$$\hat{\xi}_n^M = \frac{1}{2} \left(1 - \frac{\bar{Y}^2}{S^2} \right) \quad \text{et} \quad \hat{\sigma}_n^M = \frac{\bar{Y}}{2} \left(1 + \frac{\bar{Y}^2}{S^2} \right).$$

4.1.2 Méthodes semi-paramétriques

4.1.2.1 Estimateur de Hill

L'**estimateur de Hill** permet d'évaluer l'épaisseur de la queue d'une distribution en se basant sur les k plus grandes valeurs de l'échantillon. L'utilisation du **Hill Plot** permet de trouver la bonne valeur de k afin de chercher un plateau de stabilité où l'estimation ne varie plus. Cela permet de limiter à la fois le biais et l'incertitude.

Définition 8. (Définition de l'estimateur de Hill)[8]

Soit $(X_{1:n}, X_{2:n}, \dots, X_{n:n})$ les statistiques d'ordre de l'échantillon défini dans la section 2.1.3, ordonnées de telle sorte que :

$$X_{1:n} \leq X_{2:n} \leq \dots \leq X_{n:n}$$

L'estimateur de Hill est une méthode semi-paramétrique utilisée pour estimer l'indice de queue ξ lorsque les données appartiennent au domaine d'attraction de Fréchet ($\xi > 0$). Pour un nombre k ($1 \leq k < n$) d'observations extrêmes retenues, l'estimateur de Hill $\hat{\gamma}_H$ est défini par la relation suivante :

$$\hat{\gamma}_H = \frac{1}{k} \sum_{i=0}^{k-1} \ln(X_{n-i:n}) - \ln(X_{n-k:n}) \quad (4.4)$$

Dans cette formulation, $X_{n-k:n}$ joue le rôle d'un seuil au-delà duquel nous calculons la moyenne des écarts logarithmiques. La performance de cet estimateur dépend fortement du choix de k .

Remarque 3. — Un k trop faible augmente la variance de l'estimation.

— Un k trop élevé introduit un biais en incluant des données n'appartenant pas à la queue de la distribution.

4.1.2.2 Choix du paramètre k et graphique de Hill

La mise en œuvre de cet estimateur nécessite donc de trouver une valeur de k optimale. Pour ce faire, on utilise généralement le graphique de Hill (*Hill plot*), qui représente les couples $\{(k, \hat{\gamma}_H(k)), k = 1, \dots, n-1\}$. L'objectif est de repérer visuellement un plateau de stabilité.

Cette approche semi-paramétrique est particulièrement robuste pour les distributions à variation régulière, car elle ne nécessite pas de spécifier entièrement la forme de la fonction de survie, contrairement aux méthodes paramétriques présentées précédemment.




FIGURE 4.1 – Graphique de Hill sur une simulation de loi de Fréchet ($\gamma = 0,5$, $n = 1000$)

L'analyse du graphique de Hill permet de dégager des règles de décision pour le choix du paramètre k (nombre de statistiques d'ordre supérieures). En nous appuyant sur la simulation réalisée (voir Figure 4.1), on peut décomposer la trajectoire de l'estimateur en trois phases distinctes :

- **Forte volatilité** ($k < 200$) : Pour les valeurs inférieures à 200, on peut décomposer le comportement de l'estimateur en deux phases distinctes :
Forte instabilité ($k < 50$) : Dans cette zone, l'estimateur est extrêmement volatil car il ne repose que sur un très petit nombre d'observations extrêmes. La variance y est à son maximum, ce qui rend toute interprétation impossible car le moindre changement dans les valeurs maximales fait varier brutalement le résultat.
Croissance monotone ($50 \leq k < 200$) : Bien que la courbe commence à se lisser, elle présente une trajectoire essentiellement monotone croissante. Cette tendance montre que l'estimateur n'a pas encore atteint un état d'équilibre ou de stationnarité.
- **Stabilité sur le plateau** ($200 \leq k \leq 275$) : Dans cette zone, la courbe oscille modérément autour de la valeur théorique $\gamma = 0,5$. C'est le comportement idéal : le nombre d'observations est suffisant pour réduire la variance sans encore introduire de biais significatif.
- **Croissance du biais** ($k > 275$) : Au-delà du plateau, on observe une dérive systématique de la courbe vers le haut. En incluant trop de données issues du corps de la distribution (qui ne suivent plus la loi de puissance), l'estimateur s'éloigne de la vraie valeur de l'indice de queue.

***Conclusion pour le choix de k :** Sur cette simulation, une valeur de k comprise entre 100 et 150 semble être le meilleur compromis, offrant une estimation proche de la réalité tout en se situant sur la zone la plus stable du graphique.*

4.1.2.3 Aide à l'interprétation : le Mean Excess Plot (ME-plot)

Avant de finaliser l'estimation par la méthode de Hill, il est d'usage d'examiner la fonction de moyenne des excès (Mean Excess Plot). Cette étape permet de confirmer le comportement des extrêmes. Trois cas de figure peuvent se présenter selon l'allure de la pente :

- **Pente positive** : Si à partir d'un certain seuil, la fonction moyenne des excès présente une pente positive, alors les données suivent une distribution de Pareto généralisée avec un paramètre ξ positif.




FIGURE 4.2 – Mean Excess Plot (Simulation Cas 1) : analyse critique de la pente

L'analyse de la Figure 4.2 confirme visuellement la présence d'une **pente positive** (Cas 1), validant le caractère à queue lourde des valeurs extrêmes. Cependant, un examen critique de la partie droite du graphique ($u > 2,5$) montre un décrochage des observations par rapport à la tendance linéaire. Ce phénomène, fréquent, n'infirme pas le Cas 1, mais illustre la **forte variance** de l'estimateur de moyenne des excès lorsque le nombre d'observations extrêmes devient trop faible.

- **Pente horizontale** : Si la fonction présente une pente horizontale, les données suivent une distribution exponentielle.

Le deuxième cas de figure (voir Figure 4.3) correspond à une **pente horizontale** de la fonction moyenne des excès. Ce comportement est caractéristique des distributions appartenant au domaine d'attraction de Gumbel, dont le représentant principal est la loi exponentielle.




FIGURE 4.3 – Mean Excess Plot (Simulation Cas 2) : Pente nulle caractéristique d'une queue exponentielle

Remarque 4. Ce cas sert de pivot entre les distributions à queue lourde (pente positive) et les distributions à queue courte (pente négative). Pour l'étude des précipitations extrêmes, si le graphique observé se rapproche de cette horizontalité, cela suggère que le risque d'événements catastrophiques est plus modéré que dans le modèle de Pareto.

- **Pente décroissante** : Si la fonction est décroissante, on est en présence d'une distribution bornée à droite.

Le troisième cas de figure (voir Figure 4.4) présente une **pente décroissante** de la fonction moyenne des excès. Ce comportement est caractéristique des distributions appartenant au domaine d'attraction de Weibull.

- **Interprétation graphique** : Plus le seuil u augmente, plus la moyenne des excès diminue de manière linéaire. La ligne de tendance rouge présente une inclinaison négative très nette, indiquant que les excès s'amenuisent à mesure que l'on s'approche d'une limite.
- **Implication statistique** : Dans ce contexte, l'indice de queue γ est négatif. Cela signifie que la distribution est bornée supérieurement par une valeur finie (un "plafond"). Les valeurs extrêmes ne peuvent pas croître indéfiniment.




FIGURE 4.4 – Mean Excess Plot (Simulation Cas 3) : Pente décroissante caractérisant une queue courte bornée à droite.

L'utilisation conjointe du *Hill Plot* et du *ME-plot* permet de sécuriser le choix de la zone de stabilité en s'assurant que le comportement linéaire attendu est bien présent dans les données. Les diverses méthodes d'estimation présentées ci-dessus présentent aussi des avantages comme des inconvénients qu'il faut souligner. L'approche GEV offre un cadre paramétrique mathématiquement solide grâce au théorème de Fisher-Tippett-Gnedenko et a une capacité à synthétiser trois comportements asymptotiques en un seul modèle, mais au prix d'une perte d'information. D'autre part, la méthode des excès au-dessus d'un seuil (GPD) permet d'exploiter davantage les observations extrêmes, au prix d'un choix délicat du seuil optimal. Par ailleurs, des estimateurs semi-paramétriques comme celui de Hill proposent une alternative plus directe pour les distributions à queue lourde sans hypothèses préalables bien qu'ils soient sensibles au choix du nombre d'observations extrêmes retenues. Ainsi, chaque méthode présente un compromis entre biais, variance et robustesse, ce qui justifie de les utiliser conjointement afin d'assurer la fiabilité des résultats.

Remarque 5. L'estimateur des moments, proposé par [9], est une extension de la méthode Hill dans le Cadre de la GEV applicable lorsque $\xi \in \mathbb{R}$.

4.2 Estimation des quantiles extrêmes

La mesure et la gestion exigent qu'on s'intéresse aux queues de distributions (valeurs extrêmes) et en particulier aux pertes que l'on peut subir avec des probabilités faibles mais non négligeables. Il s'agit d'un **événement à occurrence rare** ou d'un **risque systémique** ou **une observation extrême structurante**. Dans l'analyse des **valeurs extrêmes**, on s'intéresse souvent à l'**estimation des quantiles extrêmes** qui jouent un rôle important dans le contexte de la gestion des risques, où il est important d'évaluer de manière adéquate le risque d'une grande perte, de sorte que les probabilités de les dépasser soient très faibles, c'est-à-dire proches de zéro. Pour ce faire, nous nous appuyons sur l'indice de queue estimé précédemment afin d'extrapoler ces niveaux de risque.

4.2.1 Estimation des quantiles extrêmes : de la théorie à la pratique

L'estimation des quantiles extrêmes est au cœur de la gestion des risques. Elle consiste à évaluer des niveaux de précipitations (ou de pertes) associés à des probabilités d'occurrence très faibles, souvent situées au-delà des observations disponibles dans l'échantillon.

4.2.1.1 Fondements théoriques et comportement asymptotique

Pour comprendre comment estimer une valeur que nous n'avons jamais observée, nous devons étudier le comportement du maximum de l'échantillon, noté $X_{n,n}$. La probabilité que ce maximum ne dépasse pas un certain seuil de risque, que nous appellerons niveau de retour x_T associé à une période de retour T , est définie par :

$$P(X_{n,n} < x_T) = F^n(x_T) = \left(1 - \frac{1}{T}\right)^n \quad (4.5)$$

Ici, $1/T$ représente la probabilité d'excéder ce seuil chaque année (un événement à occurrence rare). Lorsque la taille de l'échantillon n devient très grande et que le risque $1/T$ devient très petit, cette relation peut être approximée par une forme exponentielle :

$$\exp\left(n \ln\left(1 - \frac{1}{T}\right)\right) \approx \exp\left(-\frac{n}{T}\right) \quad \text{quand } T \rightarrow \infty \quad (4.6)$$

Cette approximation est fondamentale : elle montre que même pour des événements rares (risques systémiques), il existe une structure mathématique stable qui permet l'extrapolation au-delà du maximum observé.

4.2.1.2 Estimation par inversion de la fonction empirique

En pratique, pour estimer un quantile d'ordre p (noté q_p), nous utilisons la fonction de répartition empirique $F_n(x)$. Celle-ci représente la proportion d'observations inférieures ou égales à x :

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i \leq x\}} \quad (4.7)$$

Le quantile estimé $\hat{q}(p)$ est alors obtenu en inversant cette fonction de répartition empirique :

$$\hat{q}(p) = F_n^{\leftarrow}(1 - p) = \inf\{x : F_n(x) \geq 1 - p\} \quad (4.8)$$

Cependant, pour les quantiles très profonds dans la queue de distribution (où $p < 1/n$), la fonction empirique atteint ses limites car elle ne contient plus de données. C'est ici que l'utilisation de l'indice de queue γ devient cruciale pour prolonger cette estimation.

4.2.2 Niveau de retour

Le concept de niveau de retour est l'application temporelle des quantiles extrêmes, essentielle pour l'interprétation des risques hydrologiques ou financiers. Le niveau de retour R_T associé à une période de retour T est la valeur qui est dépassée, en moyenne, une fois tous les T ans (ou unités de temps). Mathématiquement, il correspond au quantile d'ordre $p = 1/T$. En utilisant l'estimateur de Weissman précédemment défini, nous obtenons :

$$\hat{R}_T = X_{(k)} \left(\frac{kT}{n} \right)^{\hat{\gamma}}$$

Cette formulation permet d'estimer, par exemple, une "crue centennale" ($T = 100$) même si l'historique des données ne couvre que 40 ou 50 ans, à condition que l'indice de queue $\hat{\gamma}$ ait été estimé sur une zone de stabilité fiable du Hill Plot.

4.2.3 Intervalles de confiance

L'extrapolation au-delà des données observées comporte intrinsèquement une incertitude. Pour quantifier la précision de nos estimations $\hat{q}(p)$, nous construisons des intervalles de confiance basés sur la normalité asymptotique de l'estimateur de Hill. Sous certaines conditions de second ordre, l'erreur sur l'indice de queue suit une loi normale :

$$\sqrt{k}(\hat{\gamma}_n - \gamma) \xrightarrow{d} \mathcal{N}(0, \gamma^2)$$

Par extension, l'intervalle de confiance pour le quantile extrapolé dépend de la variance de $\hat{\gamma}$ et de la distance d'extrapolation. Plus le niveau de risque p est petit (c'est-à-dire plus T est grand), plus l'intervalle de confiance s'élargit, reflétant la perte de certitude statistique lorsqu'on s'éloigne des données observées. En pratique, nous visualisons cette incertitude sur le graphique de Hill par les bandes de confiance (lignes jaunes ou pointillés) qui encadrent l'estimation.

Chapitre 5

Application sur données réelles

5.1 Présentation des données

La zone d'étude est constituée de la station hydrométrique L800001020, située sur le cours d'eau de la Loire à Saumur, dans le département de Maine-et-Loire 49 qui ont été extraites du site www.hydro.eaufrance.fr. Cette station appartient au bassin hydrographique Loire-Bretagne, l'un des principaux bassins versants français. Elle assure le suivi des débits de la Loire à pas de temps journalier, permettant l'analyse de la dynamique hydrologique du fleuve sur une longue période d'observation. Les données exploitées correspondent au débit moyen journalier, utilisé pour l'étude des variations hydrologiques et des régimes d'écoulement sur une période donnée du 1er Janvier 1989 au 31 Décembre 2025. L'analyse des valeurs extrêmes est extrêmement utile en hydrologie car elle est utilisée par exemple pour évaluer les risques d'inondation.

5.1.1 Nettoyage et exploration

Nous avons exploré le jeu de données à l'aide d'analyses descriptives après le prétraitement du jeu de données.

Statistiques	Min	1st Qu.	Median	Mean	3rd Qu.	Max	Kurtosis
Valeurs	79500	213146	404624	597286	802754	4750000	8.930401

TABLE 5.1 – Résumé statistique des données

Une analyse descriptive du jeu de données sur la période 1989-2025 révèle une amplitude hydrologique extrême, marquée par un débit maximal (4 750 000 L/s) soixante fois supérieur au minimum observé. La nette supériorité de la moyenne (597 286 L/s) par rapport à la médiane (404 624 L/s) confirme une forte asymétrie positive, indiquant que la distribution est tirée par des événements rares de grande magnitude. La valeur du kurtosis est d'environ $8.930401 > 3$ donc la distribution des débits journaliers est bien à queue lourde et donc une forte présence de valeurs extrêmes dans le jeu de données.




FIGURE 5.1 – Boîtes à moustaches des débits journaliers

La boîte à moustaches nous montre que si la plupart des débits restent bas, la longue suite de points en hauteur révèle de nombreuses crues exceptionnelles qui montent jusqu'à 4 750 000 L/s représentant les valeurs extrêmes.




FIGURE 5.2 – Debit journalier

Ce graphique nous montre l'évolution des débits sur plus de 36 ans, où l'on distingue clairement l'alternance régulière entre les périodes de basses eaux et les pics de crues. On remarque également que certains sommets dépassent très largement les autres, illustrant la rareté et l'intensité des événements extrêmes que nous cherchons à modéliser.

5.2 Mise en œuvre des modèles paramétriques et non paramétriques

À l'aide du package **Extreme Value Analysis (extRemes)** du logiciel **R**, nous avons procédé à l'estimation par la méthode du maximum de vraisemblance des paramètres de la GEV et GPD. L'algorithme d'optimisation utilisé ici pour l'estimation des paramètres est la méthode de quasi-Newton BFGS.

5.2.1 Estimation des paramètres GEV et GPD

5.2.1.1 Estimation des paramètres de GEV

Pour estimer les paramètres par cette méthode, nous avons groupé les données par blocs annuels et extrait chaque maximum, puis ajuster le modèles GEV aux maxima des blocs. Les résultats d'estimation des paramètres de chacun de ces modèles sont présentés ci-après.

Paramètres	95% lower CI	Estimations	95% upper CI
Localisation ($\hat{\mu}$)	2.177485×10^6	2.429711×10^6	2.681936×10^6
Échelle ($\hat{\sigma}$)	4.900715×10^5	7.043484×10^5	9.186253×10^5
Forme ($\hat{\xi}$)	-4.399627×10^{-1}	-1.362536×10^{-1}	1.674555×10^{-1}

TABLE 5.2 – Estimation des paramètres de la distribution GEV et intervalles de confiance à 95% obtenus par MLE

Ce tableau présente les estimateurs des paramètres ($\hat{\mu}, \hat{\sigma}, \hat{\xi}$) de la loi GEV obtenus par maximum de vraisemblance à partir des maxima annuels. Les paramètres de localisation et d'échelle sont significativement différents de zéro au seuil de 5

Le paramètre de forme est estimé à $\hat{\xi} = -1.36 \times 10^{-1}$, mais son intervalle de confiance à 95% contient la valeur 0. Par conséquent, il n'est pas possible de conclure de manière significative à une queue de type Weibull ou Fréchet. Le cas $\xi = 0$, correspondant à la loi de Gumbel, reste donc compatible avec les données.




FIGURE 5.3 – Diagnostic du GEV

Quantile-Quantile (Q-Q) Plot (Haut à gauche) : Il compare les débits mesurés aux débits prédits par le modèle. C'est le test le plus important pour confirmer que le paramètre de forme (ξ) est correct et que le modèle ne sous-estime pas les crues majeures. On constate ici que les données réelles semblent suivre une distribution de Fréchet, prouvant que le modèle GEV s'adapte aux débits extrêmes

Probability Plot (Haut à droite) : Ce graphique compare les probabilités observées (les points) aux probabilités théoriques du modèle (la ligne). Il sert à vérifier la validité globale du modèle ; plus les points sont proches de la ligne, plus la loi GEV est jugée pertinente pour décrire l'ensemble des données. Presque tous les points se situent à l'intérieur des bandes de confiance en pointillés.

Density Plot (Bas à gauche) : Ce graphique superpose la courbe des données réelles (en noir) et la courbe théorique de la loi GEV (en bleu pointillé). Il permet de visualiser si la "forme" générale de la distribution (son épaisseur et son étalement) correspond bien à la réalité du fleuve. Les deux courbes sont très proches, avec un pic bien aligné autour des valeurs fréquentes. La représentation graphique de la densité de notre modèle est donc adéquate avec la densité de Fréchet.

Return Level Plot (Bas à droite) : C'est le graphique de prédiction : il montre le débit attendu selon la période de retour (par exemple, la crue centennale). C'est l'outil final pour l'aide à la décision ; il permet de lire directement quel débit maximum le fleuve pourrait atteindre d'ici 2, 5, 10, 20, 50, 100, 200 ou 500 ans. La courbe noire monte vers le haut avec des pointillés qui représentent l'intervalle de confiance.

5.2.1.2 Estimation des paramètres de GPD

La détermination du seuil u dans le cadre de la GPD est en pratique un peu délicate. Pour ce faire, nous avons utilisé deux méthodes graphiques, celle du Mean Excess Plot et une seconde méthode graphique basée sur la stabilité de l'indice de queue. ξ .




FIGURE 5.4 – Graphique du Mean Excess Plot




FIGURE 5.5 – Graphique de stabilité de l'indice de queue

L'analyse conjointe des deux graphiques montre qu'en dessous de $2,8 \times 10^6$, les données ne suivent pas encore une loi de Pareto. C'est à partir de ce seuil que le paramètre de forme se stabilise et que la courbe de la moyenne des excès devient remarquablement rectiligne. Au-delà de $3,5 \times 10^6$, le manque de données crée une forte instabilité. On peut choisir un seuil entre $2,8 \times 10^6$ et 3×10^6 .

Les résultats des estimations sont présentés dans le tableau 5.3 ci-dessous.

Paramètre	95% lower CI	Estimations	95% upper CI
Échelle ($\hat{\sigma}$)	3.303540×10^5	3.386292×10^5	3.469044×10^5
Forme ($\hat{\xi}$)	-1.188047×10^{-1}	2.686416×10^{-2}	1.725331×10^{-1}

TABLE 5.3 – Estimation des paramètres GPD avec intervalles de confiance à 95%

Cette table présente les estimateurs des paramètres ($\hat{\sigma}, \hat{\xi}$) de la loi GPD utilisés pour modéliser le comportement des crues. Le paramètre de forme estimé est $\hat{\xi} = 2.69 \times 10^{-2}$, avec un intervalle de confiance à 95% donné par $[-1.19 \times 10^{-1}, 1.73 \times 10^{-1}]$. Comme cet intervalle contient la valeur 0, le paramètre de forme n'est pas significativement différent de zéro au seuil de 5%. Cela suggère que les données sont compatibles avec un modèle à queue exponentielle (cas particulier de la GPD avec $\xi = 0$), ce qui est cohérent avec un comportement de type Gumbel pour les extrêmes.




FIGURE 5.6 – Diagnostic du GPD

Quantile-Quantile (Q-Q) Plot (Haut à gauche) : En analysant ce graphique, contrairement au QQ plot dans le cadre de la GEV, on constate un ajustement très médiocre : les points (données réelles) s'écartent massivement de la ligne droite, prouvant que le modèle GPD surestime considérablement les débits extrêmes et n'est pas adapté à cette série de données.

Probability Plot (Haut à droite) : Ici les points suivent la ligne rouge à part quelques points qui s'écartent.

Density Plot (Bas à gauche) : Les deux courbes ne sont pas superposées, celle confirme donc les conclusions tirées à partir de l'analyse précédente du QQ plot.

Return Level Plot (Bas à droite) : modélise l'évolution des débits extrêmes selon leur fréquence d'occurrence, confirmant que les observations historiques restent bien encadrées par les intervalles de confiance du modèle pour des prédictions à long terme réalistes, malgré quelques points en dehors de l'intervalle de confiance.

Les diagnostics graphiques réalisés précédemment, en particulier les QQ-plots, mettent en évidence une meilleure adéquation du modèle GEV à nos données et ce dernier décrit de manière plus appropriée le comportement des extrêmes observés.

Nos résultats vont bien dans le sens de littérature existante qui confirme que dans le cadre des données hydrologiques, l'indice de queue est généralement positif ou nul [11, 12]

5.2.2 Estimation par la méthode semi paramétriques de Hill

À l'aide du package **evir** (**Extremes values in R**) nous avons estimé les paramètres et les résultats obtenus sont présentés ci-après.




FIGURE 5.7 – Paramètres estimés par la l'estimateur semi paramétrique de Hill

Le ξ estimé ici par cette méthode est d'environ 0.34 strictement positif, ce qui correspond donc à une loi de Fréchet.

5.2.3 Estimation des quantiles de retour

5.2.3.1 Estimation des quantiles de retour pour le modèle GEV

Dans cette partie on va donner des prévisions à court terme et à long terme pour la période de retour, le niveau de retour et l'intervalle de confiance associé. Les résultats obtenus sont les suivants :

Période de retour	IC 95% inférieur	Estimation	IC 95% supérieur
5 ans	3043483	3385227	3726971
10 ans	3361786	3794794	4227801
20 ans	3555315	4150203	4745091
50 ans	3658149	4561399	5464649
100 ans	3649367	4837067	6024767
200 ans	3584248	5086846	6589444

TABLE 5.4 – Niveaux de retour avec intervalles de confiance à 95% par le modèle GEV

Interprétation des résultats :

Dans cette partie, nous présentons les prévisions à court et à long terme basées sur le modèle GEV.

1. À court terme (5 ans - 10 ans)

- **Pour 5 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{5}$ pour avoir un niveau de crue moyen de 3 385 227 L/s. Ce résultat est statistiquement significatif au seuil $\alpha = 5\%$, avec un intervalle de confiance [3 043 483 ; 3 726 971].

- **Pour 10 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{10}$ pour avoir un niveau de crue moyen de 3 794 794 L/s. Ce résultat est statistiquement significatif au seuil $\alpha = 5\%$, avec un intervalle de confiance [3 361 786 ; 4 227 801].
2. À long terme (100 ans - 200 ans)
- (a) **Pour 100 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{100}$ pour avoir un niveau de crue moyen de 48 370 678 L/s. L'estimation reste significative au seuil $\alpha = 5\%$, bien que l'incertitude augmente avec un intervalle s'étendant de [3 649 367 ; 6 024 767].
 - (b) **Pour 200 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{200}$ pour avoir un niveau de crue moyen de 5 086 846 L/s. Ce résultat, bien que hautement théorique, illustre le risque extrême pour lequel la borne supérieure de l'intervalle de confiance atteint 6 589 444 L/s, dont l'estimation reste significative au seuil de $\alpha = 5\%$.

5.2.3.2 Estimation des quantiles de retour pour le modèle GPD

Après l'étude de la GEV pour les estimations des quantiles de retour, cette section expose les résultats des estimations pour les quantiles de retour du modèle GPD.

Période de retour	IC 95% inférieur	Estimation	IC 95% supérieur
5 ans	3633432	3820453	4007473
10 ans	3782360	4074671	4366983
20 ans	3905971	4333669	4761367
50 ans	4030536	4683530	5336524
100 ans	4094645	4953971	5813296
200 ans	4131903	5229494	6327086

TABLE 5.5 – Niveaux de retour avec intervalles de confiance à 95% estimé par le modèle GPD

Interprétation des résultats :

Dans cette partie, nous présentons les prévisions à court et à long terme basées sur le modèle GPD.

1. À court terme (5 ans - 10 ans)
- **Pour 5 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{5}$ pour avoir un niveau de crue moyen de 3 820 453 L/s. Ce résultat est statistiquement significatif au seuil $\alpha = 5\%$, avec un intervalle de confiance [3 633 432 ; 4 007 473].
 - **Pour 10 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{10}$ pour avoir un niveau de crue moyen de 4 074 671 L/s. Ce résultat est statistiquement significatif au seuil $\alpha = 5\%$, avec un intervalle de confiance [3 782 360 ; 4 366 983].
2. À long terme (100 ans - 200 ans)
- (a) **Pour 100 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{100}$ pour avoir un niveau de crue moyen de 4 953 971 L/s. L'estimation reste significative au seuil $\alpha = 5\%$, bien que l'incertitude augmente avec un intervalle s'étendant de [4 094 645 ; 5 813 296].
 - (b) **Pour 200 ans** : On a une probabilité $\frac{1}{T} = \frac{1}{200}$ pour avoir un niveau de crue moyen de 5229494 L/s. L'estimation reste significative au seuil de $\alpha = 5\%$ avec un intervalle de confiance [4 131 903 ; 6 327 086].

Les résultats concernant la période de retour complètement différents peut être dû à la richesse (en termes de taille d'échantillon) de la GPD par rapport au GEV.

5.3 Limites et perspectives

La théorie des valeurs extrêmes présente plusieurs limites. En effet, bien que le modèle semble adapté à nos données, il faut souligner sa sensibilité par rapport au seuil optimal choisi. Un seuil très bas peut notamment en inclure bon nombres de valeurs non extrêmes, ce qui introduit un biais dans les différentes estimations. Et de même un seuil très élevé donne des estimations à variance très élevée. Une légère variation du seuil peut aussi modifier de façon significative les niveaux de retour. Il faut donc en pratique trouver le bon seuil pour un bon compromis entre biais et variance ce qui n'est pas toujours évident. Aussi, la validité des résultats repose sur bon nombre d'hypothèses qui ne sont pas forcément vérifiées en pratique. **L'hypothèse de données indépendantes et identiquement distribuées** (les séries temporelles en pratique violent souvent cette hypothèse) n'est pas forcément vérifiée car, par exemple, si le fleuve est en crue aujourd'hui, la probabilité qu'il le soit le lendemain est très forte. Nos données étant à dimension temporelle, les effets de tendance et de saisonnalité conduisent donc à la non-stationnarité, qui peut être problématique dans le cadre des prévisions futures basées sur les données antérieures notamment. Les modèles utilisés dans cette étude supposant **une stationnarité dans les données**, on pourrait envisager pour des études futures d'utiliser des modèles non stationnaires pouvant capturer la tendance ou la saisonnalité présente dans les données afin de produire des estimations plus robustes et plus fiables. Aussi, des approches multivariées ou spatiales peuvent être envisagées afin de modéliser conjointement plusieurs stations hydrométriques, en tenant compte des dépendances spatiales entre sites. Cela offrirait une vision plus globale et améliorerait ainsi la précision des estimations réalisées.

Conclusion

Dans ce travail, nous avons étudié les principaux fondements de la théorie des valeurs extrêmes, outil statistique essentiel pour la modélisation des événements rares. À travers les approches GEV et GPD, nous avons montré comment il est possible de décrire le comportement des queues de distribution et d'estimer des niveaux de risque associés à des phénomènes extrêmes.

Nous avons également présenté différentes méthodes d'estimation, paramétriques et semi-paramétriques, ainsi que les outils graphiques permettant de choisir un seuil adapté et d'évaluer la stabilité des estimations. L'application réalisée sur les données hydrologiques de la Loire à Saumur a mis en évidence la présence de valeurs extrêmes importantes et a confirmé l'intérêt de la théorie des valeurs extrêmes dans l'étude des risques d'inondation.

Les résultats obtenus montrent que les modèles étudiés permettent de représenter correctement le comportement des débits extrêmes, malgré certaines limites liées au choix du seuil, à la taille de l'échantillon extrême et à l'incertitude des extrapolations. Enfin, ce travail ouvre des perspectives intéressantes pour l'étude de modèles plus complexes intégrant la non-stationnarité et l'évolution des phénomènes climatiques extrêmes.

Annexes

Annexe 1

Nous détaillons dans cette partie de l'annexe le code R

```
install.packages("hubeau")

library(httr)
library(jsonlite)
library(tidyverse)
library(zoo)
library(moments)
library(extRemes)
library(evmix)

url <- paste0(
  "https://hubeau.eaufrance.fr/api/v2/hydrometrie/obs_elab?",
  "code_entite=L800001020",
  "&grandeur_hydro_elab=QmnJ",
  "&date_debut_obs_elab=1989-01-01",
  "&date_fin_obs_elab=2025-12-31",
  "&size=20000&format=json"
)

r <- GET(url, add_headers("User-Agent"="Mozilla/5.0"))

status_code(r)

txt <- content(r, as="text", encoding="UTF-8")
obs <- fromJSON(txt)
data <- obs$data

head(data)

sum(is.na(data)) # Vérification des valeurs manquantes

# Analyses descriptives
summary(data$resultat_obs_elab)

data$date_obs_elab <- as.Date(data$date_obs_elab)
data <- data %>% arrange(date_obs_elab)

# Visualisation série temporelle
ggplot(data, aes(x = date_obs_elab, y = resultat_obs_elab)) +
  geom_line(color = "steelblue") +
  labs(title = "Débits journaliers de la Loire à Saumur (1989-2025)",
        x = "Date", y = "Débit (m3/s)") +
```

```

theme_minimal()

# Boxplot
ggplot(data, aes(y = resultat_obs_elab)) +
  geom_boxplot() +
  labs(y = "Valeurs", x = "") +
  theme_minimal()

# Kurtosis
kurtosis(data$resultat_obs_elab)

# =====
# GEV (maxima annuels)
# =====

max_annuels <- data %>%
  mutate(annee = as.numeric(format(as.Date(date_obs_elab), "%Y"))) %>%
  mutate(flow = resultat_obs_elab) %>%
  group_by(annee) %>%
  summarise(
    max_debit = max(flow, na.rm = TRUE),
    nb_jours_valides = sum(!is.na(flow))
  ) %>%
  ungroup()

fit_gev <- fevd(max_annuels$max_debit, type = "GEV", method = "MLE")

fit_gev

ci(fit_gev, alpha = 0.05, type = "parameter")

plot(fit_gev)

par(mfrow = c(2,2))
return.level(fit_gev,
  return.period = c(5,10,20,50,100,200),
  do.ci = TRUE)

# =====
# GPD (POT)
# =====

fit_gpd <- fevd(data$resultat_obs_elab,
  threshold = 2900000,
  type = "GP",
  method = "MLE")

fit_gpd

ci(fit_gpd, alpha = 0.05, type = "parameter")

plot(fit_gpd)

```

```

return.level(fit_gpd,
             return.period = c(5,10,20,50,100,200),
             do.ci = TRUE)

mrlplot(data$resultat_obs_elab)

threshrange.plot(data$resultat_obs_elab,
                 r = c(79500, 4750000),
                 nint = 100,
                 na.action = na.fail,
                 verbose = TRUE,
                 set.panels = FALSE)

# =====
# Estimation non paramétrique
# =====

debit_sort <- sort(data$resultat_obs_elab, decreasing = TRUE)
n_data <- length(data$resultat_obs_elab)

h <- hillplot(data$resultat_obs_elab)
str(h)

```


Annexe 2

Nous présentons dans cette partie de l'annexe les sorties de R.

```
fevd(x = max_annuels$max_debit, type = "GEV", method = "MLE")

[1] "Estimation Method used: MLE"

Negative Log-Likelihood value: 552.4797

Estimated parameters:
      location      scale      shape
2.429711e+06  7.043484e+05 -1.362536e-01

Standard Error Estimates:
      location      scale      shape
1.286889e+05  1.093270e+05  1.549565e-01

Estimated parameter covariance matrix.
      location      scale      shape
location  1.656083e+10  3.071688e+09 -6.920292e+03
scale     3.071688e+09  1.195238e+10 -9.804525e+03
shape    -6.920292e+03 -9.804525e+03  2.401151e-02

AIC = 1110.959

BIC = 1115.792
```

FIGURE 5.8 – Résultats GEV

```
fevd(x = max_annuels$max_debit, type = "GEV", method = "MLE")

[1] "Normal Approx."

      95% lower CI Estimate 95% upper CI
5-year return level    3043483 3385227    3726971
10-year return level   3361786 3794794    4227801
20-year return level   3555315 4150203    4745091
50-year return level   3658149 4561399    5464649
100-year return level  3649367 4837067    6024767
200-year return level  3584248 5086846    6589444
```

FIGURE 5.9 – Quantiles de retour GEV

```
fevd(x = data$resultat_obs_elab, threshold = 3e+06, type = "GP",
      method = "MLE")

[1] "Estimation Method used: MLE"

Negative Log-Likelihood value: 1219.252

Estimated parameters:
      scale      shape
3.161912e+05 2.827187e-10

Standard Error Estimates:
      scale      shape
2.2567697 0.0671591

Estimated parameter covariance matrix.
      scale      shape
scale 5.093009e+00 -9.240884e-06
shape -9.240884e-06 4.510344e-03

AIC = 2442.503

BIC = 2447.435
```

FIGURE 5.10 – Résultats GPD

```
fevd(x = data$resultat_obs_elab, threshold = 2900000, type = "GP",
      method = "MLE")

[1] "Estimation Method used: MLE"

Negative Log-Likelihood value: 1436.039

Estimated parameters:
      scale      shape
3.386292e+05 2.686416e-02

Standard Error Estimates:
      scale      shape
4.222110e+03 7.432223e-02

Estimated parameter covariance matrix.
      scale      shape
scale 1.782621e+07 -35.954376879
shape -3.595438e+01 0.005523794

AIC = 2876.079

BIC = 2881.329
```

FIGURE 5.11 – Quantiles de retour GPD

Bibliographie

- [1] Dempster A.P., Laird N.M, Rubin D.B, *Maximum likelihood from incomplete data via the EM algorithm.* J. Roy. Stat. Soc. B. 39-1 (1977), pp 1-38
- [2] Coles Stuart., *An Introduction to Statistical Modeling of Extreme Values.* Springer, London, 2001.
- [3] Hubert P., Bendjoudi H., Introduction à l'étude des longues séries pluviométriques. XIIème journées hydrologiques de l'Orstom, pp. 10–11, 1996.
- [4] Fisher, R. A., Tippett, L. H. C. (1928, April). Limiting forms of the frequency distribution of the largest or smallest member of a sample. In Mathematical proceedings of the Cambridge philosophical society (Vol. 24, No. 2, pp. 180-190). Cambridge University Press
- [5] Gnedenko, B. (1943). Sur la distribution limite du terme maximum d'une serie aleatoire. *Annals of mathematics*, 44(3), 423-453.
- [6] Resnick, S. I. (1987). *Extreme Values, Regular Variation, and Point Processes.* Springer-Verlag. Chapter 0 & 1.
- [7] Christian Y. Robert, *Théorie des valeurs extrêmes*, ISFA, Université Lyon 1, ENSAE 3A, Mars–Avril 2016.
- [8] Hill, B. M. (1975). A simple general approach to inference about the tail of a distribution. *The Annals of Statistics*, 3(5), 1163-1174.
- [9] Dekkers, A. L., Einmahl, J. H., De Haan, L. (1989). A moment estimator for the index of an extreme-value distribution. *The Annals of Statistics*, 1833-1855.
- [10] SMITH, R. L. (1985). Maximum likelihood estimation in a class of non regular cases. *Biometrika* 72, 67-90.
- [11] Buishand, T.A. (1989), Statistics of extremes in climatology. *Statistica Neerlandica*, 43 : 1-30.
- [12] Harremoës, P. and Mikkelsen, P. S. (1995). *Properties of Extreme Point Rainfall I : Results from a Rain Gauge System in Denmark.* *Atmospheric Research*, 37(4), 277–286. Elsevier.